UNIVERSIDAD COMPLUTENSE DE MADRID
FACULTAD DE CIENCIAS MATEMÁTICAS
Grado en Matemáticas y Ciencia de Datos

Segmentación y valoración de futbolistas mediante aprendizaje automático



Trabajo de Fin de Grado
Curso 2025/2026

Autor: **Álvaro Mosquera Taboada**
Tutor: **Juan Tinguaro Rodríguez González**

Resumen

Este Trabajo de Fin de Grado diseña y valida un sistema de *scouting* de futbolistas basado en datos públicos (FBref, temporada 2022/23, en las siete grandes ligas europeas). El sistema articula tres tareas encadenadas: (i) la segmentación de los jugadores en roles tácticos homogéneos mediante agrupamiento no supervisado (*K*-means, validado con los índices clásicos, el método CRB-NCE y estabilidad por *bootstrap*); (ii) la valoración explicable de cada jugador dentro de su rol mediante un sistema de *rating* construido sobre las contribuciones SHAP de un *random forest*; y (iii) un recomendador de fichajes basado en distancia ponderada. La aportación metodológica central es el filtrado direccional de SHAP, asegurando que la valoración premie únicamente las características que un rol exige por presencia y no por ausencia. El sistema se valida de forma interna, externa (frente al valor de mercado de los jugadores en Transfermarkt) y predictiva (con los fichajes del mercado de invierno de esa temporada), mostrando recomendaciones futbolísticamente coherentes y capacidad de anticipación al mercado.

Abstract

This Bachelor's Thesis designs and validates a football *scouting* system based on public data (FBref, 2022/23 season, across the seven major European leagues). The system articulates three chained tasks: (i) the segmentation of players into homogeneous tactical roles through unsupervised *clustering* (*K*-means, validated with classical indices, the CRB-NCE method and *bootstrap* stability); (ii) the explainable valuation of each player within their role through a *rating* system built on the SHAP contributions of a *random forest*; and (iii) a transfer recommender based on weighted distances. The central methodological contribution is the directional filtering of SHAP contributions, which ensures that the valuation rewards only the attributes that a role demands by presence and not by absence. The system is validated internally, externally (against player market values from Transfermarkt) and predictively (with the winter transfer window of that same season), showing tactically coherent recommendations and the ability to anticipate the market.

Índice

1. Introducción *1*

2. Preliminares *2*

2.1. El aprendizaje automático **2**

2.2. Tipologías del aprendizaje automático **3**
2.2.1. Aprendizaje supervisado 3
2.2.2. Aprendizaje no supervisado 4
2.2.3. Aprendizaje por refuerzo 5

2.3. El problema práctico: descripción, datos y metodología **5**
2.3.1. El problema y las tareas 5
2.3.2. Los datos 5
2.3.3. Metodología 6

3. Técnicas empleadas *8*

3.1. Agrupamiento **8**
3.1.1. *K*-means 8
3.1.2. Modelos de mixtura gaussiana 9
3.1.3. Fuzzy c-means 10

3.2. Validación y elección del número de grupos **11**
3.2.1. Índices clásicos 11
3.2.2. Método CRB-NCE 12
3.2.3. Estabilidad por *bootstrap* y ARI 13

3.3. Reducción de dimensionalidad **14**
3.3.1. Análisis de componentes principales 14
3.3.2. t-SNE 15
3.3.3. UMAP 16

3.4. Random forest **16**
3.4.1. Árboles de decisión 17
3.4.2. Del árbol al bosque 17

3.5. Explicabilidad con SHAP **18**
3.5.1. Valores de Shapley 18
3.5.2. SHAP 19
3.5.3. TreeSHAP 19
3.5.4. Filtrado direccional de SHAP 20

4. Desarrollo metodológico *21*

4.1. Arquitectura del sistema **21**

4.2. Fase 1. Segmentación por roles **22**
4.2.1. División por líneas y doble configuración 22
4.2.2. Agrupamiento y elección del número de roles 22
4.2.3. Tratamiento de la ambigüedad 22
4.2.4. Etiquetado de roles 23

4.3. Fase 2. Valoración explicable **23**
4.3.1. Modelo de clasificación y obtención de los pesos 23
4.3.2. Construcción del *rating* 23
4.3.3. Los cinco enfoques de valoración 24

4.4. Fase 3. Recomendador de fichajes **24**
4.4.1. Los tres modos de recomendación 25
4.4.2. Coherencia con la valoración 25

4.4.3. Filtros de uso práctico 26

5. Resultados y validación del sistema ***27***

5.1. Resultados de la segmentación **27**

5.1.1. Elección del número de roles 27

5.1.2. Los roles identificados 29

5.1.3. Volumen vs ratios 30

5.1.4. Análisis de ambigüedad 30

5.2. Resultados de la valoración **32**

5.2.1. Impacto del filtrado direccional 32

5.2.2. *Ratings* resultantes 34

5.2.3. *Rating* específico vs *Rating core* 34

5.3. Resultados del recomendador **35**

5.4. Validación externa con valor de mercado **36**

5.5. Validación predictiva: el mercado de invierno **39**

6. Conclusiones ***40***

Bibliografía ***41***

Anexo A. Variables del conjunto de datos ***43***

Anexo B. Resultados detallados ***44***

Anexo C. Pesos de los enfoques de valoración ***48***

Anexo D. Diagnósticos del modelo de regresión ***52***

1. Introducción

El *scouting,* la detección, observación y evaluación de jugadores con la que los clubes identifican talento y deciden sus fichajes, se enfrenta a una dificultad de fondo: comparar objetivamente a futbolistas que juegan en contextos, equipos y competiciones distintos.

Tradicionalmente esta tarea ha recaído en la observación experta, un recurso valioso pero subjetivo, difícil de sistematizar y limitado en alcance, pues ningún cuerpo técnico puede seguir a los miles de jugadores que compiten a la vez en las grandes ligas.

La disponibilidad de datos detallados de rendimiento, eventos por partido, métricas por noventa minutos o valores derivados como los goles esperados (xG) y las asistencias esperadas (xA), ha permitido complementar ese juicio con herramientas cuantitativas, objetivas y reproducibles. En 2012 el Arsenal FC adquirió la empresa de analítica StatDNA y la incorporó como su departamento interno de ciencia de datos, que respalda sus decisiones de fichaje [1]. Entre sus herramientas había buscadores de jugadores similares. Con uno de ellos se identificó a Lucas Torreira a partir del perfil de N'Golo Kanté, una idea próxima al recomendador de este trabajo.

Sin embargo, llevar el dato al *scouting* plantea dos dificultades que motivan este trabajo. La primera es que la posición nominal de un jugador (lateral, mediocentro, extremo) es un mal descriptor de su función real, que depende de su rol en el campo; agrupar a los jugadores por su rendimiento, y no por su etiqueta, exige técnicas de aprendizaje no supervisado. La segunda es la tensión entre potencia e interpretabilidad, una valoración basada en pesos fijados de antemano por el analista arrastra su subjetividad, mientras que los modelos más potentes tienden a comportarse como cajas negras, algo poco útil cuando un *scout* necesita justificar por qué un jugador recibe una nota.

Este Trabajo de Fin de Grado aborda ambas cuestiones diseñando y validando un sistema de *scouting* basado íntegramente en datos públicos, que articula tres tareas encadenadas:

- Segmentar a los jugadores en roles tácticos homogéneos a partir de su rendimiento, sin recurrir a las etiquetas de posición, mediante agrupamiento no supervisado.
- Valorar a cada jugador dentro de su rol con un sistema de *rating* explicable, capaz de explicar qué características fundamentan la valoración.
- Recomendar jugadores similares a uno dado, como apoyo directo a la búsqueda de sustitutos o alternativas en el mercado.

Frente a esa segunda dificultad, la principal aportación metodológica es el filtrado direccional de las contribuciones SHAP, que descarta de la valoración lo que define a un rol por su ausencia y conserva solo lo que lo define por su presencia. Para comprobarlo, el sistema se somete a tres niveles de validación de exigencia creciente: una interna, una comparación con los valores de mercado de Transfermarkt y un contraste con los traspasos reales del mercado de invierno de esa misma temporada.

La memoria se organiza como sigue. El capítulo 2 recoge los preliminares, con el aprendizaje automático, el problema práctico y los datos. El capítulo 3 desarrolla las técnicas desde el punto de vista matemático y el capítulo 4 detalla el proceso metodológico del sistema. El capítulo 5 presenta y valida los resultados, y el capítulo 6, las conclusiones y líneas futuras. El Anexo A recoge las variables del conjunto de datos y el Anexo B, resultados detallados. El código completo de la implementación, con todos los experimentos, está disponible en un cuaderno de Google Colab [2].

2. Preliminares

Este capítulo establece el marco en el que se inscribe el trabajo. Presenta primero el aprendizaje automático y sus tipologías, y concreta después el problema práctico que se aborda, los datos empleados y la metodología que conecta ambos mundos.

2.1. El aprendizaje automático

El aprendizaje automático (ML, del inglés *machine learning*) es una subdisciplina de la inteligencia artificial que estudia algoritmos capaces de resolver tareas complejas sin que sus instrucciones hayan sido programadas de antemano, a partir de la experiencia o de la interacción con datos. En lugar de codificar a mano las reglas de resolución, se proporciona al sistema un conjunto de datos (o un contexto con el que interactuar) y un criterio de calidad, y es el propio algoritmo el que construye o ajusta un procedimiento que mejora su desempeño conforme dispone de más información o experiencia. Esa capacidad de inducir un comportamiento a partir de ejemplos, en vez de deducirlo de un programa fijo, es lo que distingue al aprendizaje automático de la programación clásica y lo que ha hecho posible abordar problemas en los que escribir reglas explícitas resulta inviable, como el reconocimiento de imágenes o el procesamiento del lenguaje natural [3].

Conviene precisar desde el principio que el aprendizaje automático no se reduce a una única forma de aprender. Existen paradigmas, como el aprendizaje por refuerzo, que no parten de un conjunto de datos estático ni realizan inferencias sobre observaciones nuevas en el sentido habitual, sino que aprenden de la interacción con un entorno. Identificar el aprendizaje automático con el aprendizaje supervisado, que es su caso más conocido, es por tanto una simplificación que conviene evitar.

El origen de la disciplina suele situarse en 1943, cuando Warren McCulloch y Walter Pitts formularon el primer modelo matemático de neurona artificial. Aquella neurona carecía de mecanismo de aprendizaje y tenía una expresividad muy limitada, pero estableció la idea de representar el cómputo neuronal mediante operaciones lógicas. En 1950 Alan Turing propuso el conocido Test de Turing como criterio para decidir si una máquina exhibe comportamiento inteligente, según el cual una máquina podría considerarse inteligente si un interlocutor humano no lograra distinguir si conversa con ella o con una persona. La prueba ha recibido críticas, ya que la inteligencia difícilmente se reduce a la imitación del comportamiento humano, pero supuso un gran hito a nivel conceptual.

En 1952 Arthur Samuel desarrolló un programa capaz de jugar a las damas que mejoraba su juego partida tras partida, empleando una búsqueda minimax y ajustando los pesos de una función de evaluación a partir de la experiencia acumulada. Samuel fue quien popularizó el término *machine learning* en 1959. Pocos años antes, en 1958, Frank Rosenblatt había construido el perceptrón de su mismo nombre, inspirado en el modelo de aprendizaje sináptico de Donald Hebb, que constituye la primera red neuronal con un mecanismo de aprendizaje y la antecesora directa de las arquitecturas actuales.

El avance no fue lineal. En 1973 el informe Lighthill cuestionó los resultados obtenidos hasta entonces y precipitó un fuerte recorte de la financiación, en lo que se conoce como el invierno de la inteligencia artificial. La década de 1980 trajo un renacimiento de la mano de los sistemas expertos, programas basados en grandes conjuntos de reglas lógicas que simulaban el juicio de especialistas humanos, pero su rigidez y su elevado coste de mantenimiento provocaron un segundo declive. El agotamiento de esa inteligencia artificial simbólica fue lo que impulsó el giro hacia el enfoque estadístico, que consolidó al aprendizaje automático basado en datos como el motor de la disciplina [4].

La última década ha vivido una expansión sin precedentes, impulsada por la disponibilidad masiva de datos y por el abaratamiento de la capacidad de cómputo. Esa combinación ha permitido el auge del aprendizaje profundo (del inglés *deep learning*), basado en redes neuronales con un número elevado de capas capaces de aprender representaciones jerárquicas de los datos, que hoy sustenta los sistemas de visión por computador y de reconocimiento de voz. Su exponente más reciente son los grandes modelos de lenguaje (LLM, del inglés *large language models*), redes de enorme tamaño ajustadas sobre cantidades ingentes de texto que han redefinido las expectativas sobre lo que un sistema automático puede llegar a hacer [5].

2.2. Tipologías del aprendizaje automático

En función de la naturaleza de los datos disponibles y del objetivo del aprendizaje, los métodos de aprendizaje automático se agrupan habitualmente en tres grandes familias, el aprendizaje supervisado, el no supervisado y el aprendizaje por refuerzo.

2.2.1. Aprendizaje supervisado

El aprendizaje supervisado se caracteriza por el uso de datos etiquetados. Se dispone de un conjunto de n pares (x_i, y_i), con $i = 1, \ldots, n$, donde cada $x_i \in X \subseteq \mathbb{R}^p$ recoge las p variables de entrada, o características, de una observación, e $y_i \in Y$ es la variable de salida asociada. Se asume la existencia de una relación $f: X \to Y$ que vincula entradas y salidas, y el objetivo es obtener una aproximación $\hat{f}$ que permita predecir la salida de observaciones nuevas, no vistas durante el ajuste, esto es, durante el proceso de estimación del modelo a partir de los datos, también llamado entrenamiento.

Conviene matizar el uso de la palabra "aprender". La mayoría de los métodos supervisados, como la regresión lineal, las redes neuronales o los árboles de decisión, son métodos globales, pues postulan un mismo modelo $\hat{f}$, descrito mediante un conjunto de parámetros y válido para todo el espacio de entrada, cuyos parámetros se ajustan minimizando una función de pérdida $L(y, \hat{f}(x))$ que mide la discrepancia entre la predicción y el valor real. Sin embargo, no todos los métodos supervisados aprenden en ese sentido. Existen métodos locales, como los k vecinos más próximos (k-NN), que no realizan un ajuste global previo, sino que construyen una predicción específica para cada punto a partir de las observaciones de su entorno. Para ellos es más preciso decir que replican localmente la relación f que afirmar que la aprenden, ya que no emplean una representación ajustable de f ni una función de pérdida que optimizar.

Esto no significa que tales métodos sean ajenos a la noción de pérdida. Bajo la pérdida cuadrática $L(y, \hat{f}(x)) = (y - \hat{f}(x))^2$, y suponiendo conocida la distribución conjunta del par (X, Y), la función que minimiza el error esperado $E[(Y - f(X))^2]$ es la esperanza condicional $f^*(x) = E[Y \mid X = x]$. Como en la práctica esa distribución se desconoce, el k-NN puede entenderse como una forma de aproximar localmente dicha esperanza promediando los valores de salida de los vecinos. Esta lectura conecta los métodos locales y globales bajo un mismo marco, ya que ambos buscan, por vías distintas, la mejor aproximación posible de f para la pérdida considerada [6].

Dentro del aprendizaje supervisado se diferencian dos tareas principales según la naturaleza de la variable de salida. En la regresión, la variable de salida es cuantitativa, es decir, mide cantidades numéricas en origen, como el precio de una vivienda o la temperatura, y el modelo predice un valor numérico. En la clasificación, la variable de salida es cualitativa, esto es, codifica categorías que no son numéricas en origen, aunque se representen con números y el modelo asigna a cada observación una de las clases posibles.

Los métodos supervisados difieren no solo en su capacidad predictiva, sino también en cómo de comprensibles son sus predicciones. Algunos, como la regresión lineal o un árbol de

decisión de poca profundidad, son interpretables: su estructura puede leerse directamente y permite entender en qué se basa cada predicción. Otros, más potentes, como las redes neuronales o los conjuntos de cientos de árboles, alcanzan mayor precisión a costa de comportarse como cajas negras, cuya lógica interna resulta ilegible incluso para quien los entrena.

Cuando un modelo de este segundo tipo se emplea en un contexto donde sus predicciones deben poder justificarse, surge la necesidad de explicarlas. De ahí nacen las técnicas de explicabilidad, procedimientos que se superponen a un modelo ya entrenado y explican sus predicciones sin modificarlo. Una de sus posibilidades más útiles es atribuir a cada variable de entrada una puntuación que cuantifica cuánto ha contribuido a una predicción concreta. Esta idea, la de explicar un modelo opaco asignando importancia a sus variables, es la que más adelante sustenta la valoración explicable que se construye en este trabajo.

2.2.2. Aprendizaje no supervisado

En el aprendizaje no supervisado se dispone únicamente de las observaciones $x_1, \ldots, x_n \in \mathbb{R}^p$, sin etiquetas asociadas. No existe una variable de salida que predecir ni una verdad de referencia frente a la que medir el acierto, y el objetivo es explorar la estructura intrínseca de los datos para descubrir patrones, agrupaciones o relaciones latentes. Esta ausencia de supervisión es la situación más frecuente en la práctica, donde etiquetar manualmente grandes volúmenes de datos resulta costoso o inviable, pero también convierte el problema en uno más ambiguo, porque sin una métrica de acierto objetiva la propia definición de lo que es una buena solución depende de los supuestos del analista. Las dos tareas fundamentales de este paradigma son el agrupamiento, que busca una estructura discreta agrupando las observaciones, y la reducción de dimensionalidad, que busca una estructura continua de menor dimensión que las describa.

El agrupamiento (del inglés *clustering*) consiste en dividir las n observaciones en k subgrupos homogéneos $C_1, \ldots, C_k$, de modo que las de un mismo grupo sean similares entre sí y distintas de las de otros grupos. Formalmente, un agrupamiento duro es una partición del conjunto de observaciones en k grupos no vacíos $\{C_1, \ldots, C_k\}$ tales que $C_1 \cup \cdots \cup C_k = \{x_1, \ldots, x_n\}$ y $C_j \cap C_l = \emptyset$ para todo $j \neq l$, es decir, cada observación pertenece a exactamente un grupo. La mayoría de los métodos buscan la partición que optimiza una función objetivo que premia la homogeneidad dentro de cada grupo, una idea que se concreta en el capítulo 3. Frente a esta asignación dura, otras técnicas realizan una asignación blanda, en la que cada observación recibe un grado o una probabilidad de pertenencia a cada grupo en lugar de adscribirse a uno solo. Es una tarea más sutil de lo que aparenta. Por un lado, no existe una única noción de grupo, ya que la similitud puede entenderse de muchas formas, y con frecuencia se trata de una cuestión de escala, pues dentro de un grupo pueden existir subgrupos a una resolución más fina. Por otro, y como consecuencia de lo anterior, los distintos algoritmos se apoyan en supuestos diferentes sobre la forma y la naturaleza de los grupos, y esos supuestos determinan su manera de operar. Estas técnicas se apoyan, además, en una noción de distancia o similitud entre observaciones, por lo que requieren que todas las variables estén expresadas en escalas comparables, algo que en la práctica se consigue mediante transformaciones previas de los datos. Entre las familias principales se encuentran los métodos basados en prototipos, como *K*-means, que agrupan en torno a un centroide y asumen grupos de forma aproximadamente esférica; los basados en distribuciones, como los modelos de mixtura gaussiana, que estiman la probabilidad de pertenencia de cada observación a cada grupo y admiten formas elípticas; los basados en densidad, como DBSCAN, que identifican regiones densas separadas por zonas poco pobladas y aíslan valores atípicos; y los de lógica difusa, como *fuzzy c-means*, que asignan a cada observación un grado de pertenencia a cada grupo. Tanto estos como los

basados en distribuciones permiten una asignación blanda: en lugar de adscribir cada observación a un único grupo, expresan la incertidumbre sobre esa asignación, si bien lo hacen desde marcos conceptuales distintos.

La reducción de dimensionalidad consiste en proyectar datos de muchas variables sobre un espacio de menor dimensión perdiendo la menor cantidad de información posible. Formalmente, se busca una aplicación $\varphi: \mathbb{R}^p \to \mathbb{R}^d$, con $d \ll p$, que transforme cada observación en una representación de menor dimensión preservando al máximo cierta estructura de los datos, como las distancias entre observaciones o la varianza total. Tiene dos aplicaciones principales. La primera es comprimir y eliminar redundancia para facilitar el almacenamiento o el procesamiento posterior. La segunda, muy habitual, es la visualización: tomando $d = 2$ o $d = 3$, los datos pueden representarse gráficamente, lo que permite hacerse una idea de su estructura y de las relaciones entre observaciones, algo imposible de inspeccionar en el espacio original. Técnicas como el análisis de componentes principales (PCA), t-SNE o UMAP responden a este propósito.

2.2.3. Aprendizaje por refuerzo

El aprendizaje por refuerzo (RL, del inglés *reinforcement learning*) se distingue de los anteriores en que no parte de un conjunto de datos estático. Un agente interactúa con un entorno dinámico: en cada instante t observa un estado s_t, ejecuta una acción a_t y recibe del entorno una recompensa r_t, positiva o negativa, junto con un nuevo estado s_{t+1}. Mediante ensayo y error, el agente actualiza su política π, que es la regla que determina qué acción tomar en cada estado, con el fin de maximizar la recompensa acumulada esperada a largo plazo. El marco formal habitual para estos problemas es el de los procesos de decisión de Markov, en los que el siguiente estado depende solo del estado y la acción actuales. Entre los enfoques de resolución más conocidos figura el *Q-learning*, que aprende una función de valor $Q(s, a)$ que estima la recompensa acumulada esperada de ejecutar la acción a en el estado s y actuar de forma óptima a partir de entonces. Este paradigma sustenta avances en robótica autónoma y en sistemas capaces de dominar juegos como el ajedrez o el Go. En el presente trabajo no se emplean técnicas de aprendizaje por refuerzo, por lo que su tratamiento se limita a esta presentación general.

2.3. El problema práctico: descripción, datos y metodología

Esta sección concreta el problema que aborda el trabajo. Se describen primero las tres tareas que lo componen, después los datos sobre los que se construye el sistema y, por último, la metodología que conecta cada tarea con las técnicas del capítulo siguiente.

2.3.1. El problema y las tareas

El objetivo práctico del trabajo es segmentar a los futbolistas por rol, valorarlos de forma explicable dentro de su rol y recomendar jugadores similares a uno dado, todo ello a partir de su rendimiento estadístico en una temporada. Son las tres tareas presentadas en la introducción: la segmentación descubre los roles, la valoración ordena a los jugadores dentro de cada rol y la recomendación localiza perfiles similares a uno dado. Para que el análisis tenga sentido, los jugadores deben describirse mediante un mismo conjunto de métricas y compararse solo con quienes desempeñan funciones parecidas.

2.3.2. Los datos

Los datos proceden de FBref [7], una de las fuentes públicas de estadística futbolística más completas, y corresponden a la temporada 2022/23 de las siete grandes ligas europeas. La información se obtuvo mediante *scraping* con la librería LanusStats [8][9], que facilita la

descarga estructurada de estadísticas desde FBref. La extracción reúne las tablas estándar, de disparos, de pases, de creación de ocasiones, de acciones defensivas, de posesión y de tiempo de juego, lo que supone un total de 63 variables en bruto por jugador antes de cualquier procesamiento. De ese conjunto inicial se descartan las métricas específicas de portero, al quedar los guardametas fuera del análisis, y, a partir de las restantes, se construyen las dos configuraciones finales: 42 variables en la de volumen y 43 en la de ratios.

Del conjunto inicial de jugadores se descartan aquellos con menos de novecientos minutos disputados, ya que sus estadísticas, en especial las expresadas por noventa minutos, no son fiables con tan pocos datos. Un caso particular son los jugadores transferidos a mitad de temporada, que en FBref aparecen con una fila por cada club en el que han jugado. Tratarlos por separado sería incorrecto, ya que se contaría a un mismo futbolista como dos entidades distintas, así que se agregan en un único registro que representa su temporada completa, sumando las métricas absolutas y recalculando las métricas por noventa minutos y los porcentajes ponderando por los minutos jugados en cada club.

No todos los nombres repetidos corresponden, sin embargo, a un jugador transferido. El conjunto contiene casos de homonimia, jugadores distintos que comparten exactamente el mismo nombre. Fusionarlos crearía un futbolista ficticio sin sentido, así que se detectan de forma automática, por diferencias de nacionalidad o de edad o por una suma de minutos imposible en una sola temporada, y se conservan como jugadores independientes, distinguiéndolos por el club. Tras todo este proceso, el análisis trabaja con 2153 jugadores.

A partir de las estadísticas en bruto se construyen las variables que describen a cada jugador, organizadas en dos configuraciones paralelas que ofrecen lecturas complementarias. La primera, de volumen, recoge la cantidad de acciones que realiza un jugador mediante métricas por noventa minutos y porcentajes, y captura qué hace en el contexto de su equipo, de modo que, por ejemplo, un central de un equipo dominador acumula muchos toques y pases simplemente porque su equipo controla el balón. La segunda, de ratios, recoge cocientes entre métricas, como los tiros a puerta por tiro o las acciones defensivas por toque, y captura cómo lo hace, su eficiencia y su tendencia de juego, de forma más independiente al estilo del equipo. Ambas configuraciones se mantienen en paralelo a lo largo de todo el análisis, lo que permite comparar el efecto de cada una en la segmentación.

Tras la construcción, cada configuración queda definida por su propio conjunto de variables: 42 en la de volumen y 43 en la de ratios, todas ellas numéricas y expresadas, respectivamente, en unidades por noventa minutos o porcentajes y en cocientes adimensionales. Una muestra del aspecto final del conjunto de datos se recoge en el Anexo A.

2.3.3. Metodología

Cada una de las tres tareas se corresponde de forma natural con una de las tipologías de aprendizaje presentadas en este capítulo. La segmentación por roles es un problema de aprendizaje no supervisado: no existen etiquetas de rol previas, así que los grupos deben descubrirse a partir de los datos mediante técnicas de agrupamiento, apoyadas en técnicas de reducción de dimensionalidad para visualizar y validar las particiones obtenidas. La valoración se apoya en el aprendizaje supervisado en combinación con la explicabilidad: se entrena un modelo de clasificación que aprende a distinguir los roles y, en lugar de usarlo para predecir, se explican sus decisiones con un método de atribución, de modo que las características que definen cada rol, y su importancia, son las que construyen el *rating*. La recomendación, por último, no requiere técnicas nuevas, sino que aplica los productos de las dos fases anteriores: mide la similitud entre jugadores con una distancia ponderada cuyos pesos proceden de la propia explicación del modelo.

El flujo de trabajo completo encadena, por tanto, un preprocesamiento de los datos, la segmentación, la valoración y la recomendación, con una validación final del sistema. Dentro del preprocesamiento, las variables se estandarizan para el agrupamiento y el cálculo de distancias, llevándolas a una escala común, y se expresan en percentiles dentro de cada rol para la valoración, de manera que el *rating* pueda interpretarse como una posición relativa entre iguales. Las técnicas concretas que sustentan cada paso se desarrollan en el capítulo 3, y el proceso metodológico completo, con las decisiones de diseño y las fórmulas de cada transformación, se detalla en el capítulo 4. La implementación íntegra del sistema, con el código de todos los experimentos, está disponible en un cuaderno de Google Colab [2].

3. Técnicas empleadas

Este capítulo presenta, desde un punto de vista matemático y con carácter general, las técnicas en las que se apoya el sistema, en el mismo orden en que intervienen en el trabajo. Se aborda primero el agrupamiento, con el *K*-means como método central y con los modelos de mixtura gaussiana y el *fuzzy c-means* como alternativas de asignación blanda, junto con las herramientas con las que se valida una partición y se elige el número de grupos. Siguen las técnicas de reducción de dimensionalidad, que permiten visualizar datos de muchas variables, y se cierra con el *random forest* y con los valores SHAP, el modelo supervisado y el método de explicabilidad sobre los que descansa la valoración. La aplicación concreta de cada técnica al problema del *scouting* se desarrolla en el capítulo 4.

3.1. Agrupamiento

El agrupamiento constituye el núcleo de la primera fase del sistema, segmentando a los jugadores en roles tácticos a partir de su rendimiento. Se empleará el *K*-means como método principal y, de manera complementaria, los modelos de mixtura gaussiana y el *fuzzy c-means,* que ofrecen una asignación blanda que nos servirá para identificar a los jugadores de perfil ambiguo.

3.1.1. *K*-means

El algoritmo *K*-means reparte un conjunto de observaciones $x_1, \ldots, x_n$, con cada x_i en $\mathbb{R}^p$, en k grupos $C_1, \ldots, C_k$, cada uno representado por un centroide μ_j. Para ello, busca la partición que minimiza una función objetivo J asociada a la suma de distancias cuadradas intra-clúster, también llamada inercia, que mide cuánto se alejan las observaciones del centroide de su grupo, esto es,

$$J = \sum_{j=1}^{k} \sum_{x_i \in C_j} ||x_i - \mu_j||^2,$$

donde ||.|| denota la norma euclídea. Encontrar la partición que minimiza J de forma global es inviable en la práctica, pues el número de maneras de dividir las observaciones en k grupos crece de manera combinatoria con el tamaño del problema. Por ello se recurre a un procedimiento iterativo que, tras inicializar de manera aleatoria los k centroides, alterna dos pasos:

1. Asignación: cada observación se asigna al clúster de centroide más próximo, es decir,

$$c_i = \arg\min_j || x_i - \mu_j ||^2.$$

2. Actualización: cada centroide se recalcula como la media de las observaciones asignadas a su clúster. Para una partición dada, ese promedio es precisamente el centroide que minimiza la suma de distancias cuadradas dentro del grupo, lo que da nombre al método. Así pues, formalmente, el centroide del grupo C_j se obtiene como

$$\mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i,$$

siendo $|C_j|$ el número de observaciones del grupo C_j. Ambos pasos se repiten hasta que las asignaciones no cambian entre dos iteraciones consecutivas o, de forma equivalente, hasta que la disminución de la función objetivo J queda por debajo de un umbral prefijado [6][10].

Como el número de particiones posibles es finito, el algoritmo convergerá en un número finito de iteraciones. Sin embargo, por la no convexidad de la inercia, la convergencia puede producirse a un mínimo local y no necesariamente al global, por lo que el resultado de este método dependerá considerablemente de la inicialización de los centroides. Para mitigar este efecto, se ejecuta en múltiples ocasiones con inicializaciones distintas, conservando aquella que minimice la inercia. Existen métodos como *K*-means++, que separa entre sí los centroides iniciales, para mejorar la inicialización y acercarse al óptimo global.

El uso de la distancia euclídea y de la media como representante hace que el *K*-means tienda a encontrar grupos de forma aproximadamente esférica y de tamaño similar, y que sea sensible a la escala de las variables, razón por la que estas se estandarizan previamente. Su limitación más característica es la necesidad de fijar de antemano el número de grupos *k*, pues el algoritmo no lo deduce de los datos, cuestión que se abordará en la próxima sección. Por su sencillez y eficiencia en problemas muy variados, es el método de agrupamiento de referencia y el que se adopta como base de la segmentación, aplicándolo de forma independiente a cada línea del campo y a cada configuración de variables.

3.1.2. Modelos de mixtura gaussiana

En contraste con la asignación rígida del *K*-means, los modelos de mixtura gaussiana (GMM, del inglés *gaussian mixture models*) realizan una asignación blanda, en la que cada observación pertenece a todos los grupos con una cierta probabilidad. Estos modelos suponen que los datos fueron generados de una mixtura de *k* distribuciones normales cada una con su propia media μ_j y su propia matriz de covarianzas Σ_j. Esta matriz de covarianzas permite que los grupos tomen formas elípticas y orientaciones distintas, aportando una flexibilidad de la que carecen los grupos esféricos de *K*-means. La función de densidad del modelo sería entonces:

$$p(x) = \sum_{j=1}^{k} \pi_j N\left(x \middle| \mu_j, \Sigma_j\right),$$

donde $N(x \mid \mu_j, \Sigma_j)$ es la densidad normal del grupo *j* y los pesos de la mixtura π_j son no negativos y suman uno, e indican la proporción de cada grupo en el conjunto. La densidad normal multivariante es

$$N(x|\mu, \Sigma) = (2\pi)^{-d/2}|\Sigma|^{-1/2} \exp\left(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right),$$

cuyo exponente contiene la distancia de Mahalanobis al cuadrado, que generaliza la distancia euclídea del *K*-means teniendo en cuenta la dispersión y correlación de cada grupo [6][11].

A partir de este modelo se calcula, para cada observación, la probabilidad de que pertenezca a cada grupo, llamada responsabilidad. La responsabilidad del grupo *j* sobre la observación *i* es

$$\gamma_{ij} = \frac{\pi_j N\left(x_i \middle| \mu_j, \Sigma_j\right)}{\sum_{l=1}^{k} \pi_l N(x_i|\mu_l, \Sigma_l)},$$

es decir, el peso del grupo *j* en el punto x_i dividido por el de todos los grupos, de modo que las responsabilidades de una observación suman uno.

Los parámetros del modelo, es decir, los pesos, las medias y las covarianzas, se estiman con el algoritmo de esperanza-maximización (EM, del inglés *expectation-maximization*), un procedimiento iterativo que va mejorando poco a poco el ajuste del modelo a los datos

alternando dos pasos. En el paso *E* se calculan, con los parámetros actuales, las responsabilidades de todas las observaciones según la fórmula anterior. En el paso *M* se reestiman los parámetros tratando esas responsabilidades como pesos, de modo que cada observación contribuye a cada grupo en la medida en que le pertenece,

$$\pi_j = \frac{1}{n}\sum_{i=1}^{n} \gamma_{ij}\,, \quad \mu_j = \frac{\sum_i \gamma_{ij} x_i}{\sum_i \gamma_{ij}}, \quad \Sigma_j = \frac{\sum_i \gamma_{ij}(x_i - \mu_j)(x_i - \mu_j)^T}{\sum_i \gamma_{ij}}.$$

Se repiten dichos pasos hasta que la verosimilitud deja de crecer de forma apreciable. Del mismo modo que en el *K*-means, EM converge a un óptimo local que depende de la inicialización. De hecho, el *K*-means puede verse como un caso límite del GMM en el que las covarianzas son esféricas e iguales y la asignación se vuelve dura, lo que conecta ambos métodos bajo una misma idea.

En este trabajo el GMM no se usa para sustituir al *K*-means, sino para aprovechar su asignación blanda y detectar a los jugadores de perfil ambiguo, aquellos cuya segunda probabilidad de pertenencia más alta es comparable a la primera y que, por tanto, se encuentran entre dos roles.

3.1.3. Fuzzy c-means

El *fuzzy c-means* es la otra técnica de asignación blanda que se emplea como complemento [12]. Comparte con el GMM el propósito de matizar la asignación de cada observación, pero su naturaleza es distinta, pues no parte de un modelo probabilístico, sino que se apoya en una versión difusa del objetivo del *K*-means. A cada observación se le asignan grados de pertenencia u_{ij} a cada grupo, valores entre cero y uno que indican cuánto pertenece la observación *i* al grupo *j* y que, para cada observación, suman uno[1]

$$\sum_{j=1}^{k} u_{ij} = 1.$$

El método busca los centroides c_j y los grados de pertenencia que minimizan la siguiente suma de cuadrados ponderada por esas pertenencias,

$$J_m = \sum_{i=1}^{n}\sum_{j=1}^{k} u_{ij}^{m} ||x_i - c_j||^2,$$

donde el exponente *m*, mayor que uno, controla el grado de difusidad. Cuanto mayor es *m*, más repartidas quedan las pertenencias entre los diferentes grupos, y en el límite, cuando *m* tiende a uno se recupera la asignación dura del *K*-means. En la práctica se suele tomar *m* = 2.

Del mismo modo que en los dos métodos anteriores, el problema se resuelve iterativamente, alternando dos actualizaciones hasta que las pertenencias se estabilizan. Los grados de pertenencia se recalculan en función de las distancias de las observaciones a cada centroide.

---

[1] El *fuzzy c-means* modifica el propio marco lógico: la afirmación "*x* pertenece al grupo *C*" deja de valorarse de forma binaria en *{0,1}* y pasa a hacerlo de forma continua en *[0,1],* de modo que una observación puede pertenecer parcial y simultáneamente a varios grupos. Esto la distingue del GMM, que mantiene el supuesto de pertenencia única y emplea las probabilidades solo para expresar la incertidumbre sobre cuál es el grupo verdadero, igual que una moneda tiene probabilidad de cara y de cruz sin estar parcialmente en ambas. En la práctica, ambos funcionan como modelos de representación de incertidumbre sobre la asignación, que es el uso que se les da en este trabajo.

$$u_{ij} = \frac{1}{\sum_{l=1}^{k} \left(\frac{||x_i - c_j||}{||x_i - c_l||} \right)^{2/(m-1)}},$$

y cada centroide se actualiza como la media de las observaciones ponderada por sus pertenencias,

$$c_j = \frac{\sum_{i=1}^{n} u_{ij}^m x_i}{\sum_{i=1}^{n} u_{ij}^m}.$$

La diferencia con el GMM es que el *fuzzy c-means* es puramente geométrico. No estima covarianzas ni probabilidades, sino que mide cercanía con la distancia euclídea, por lo que hereda el supuesto de grupos esféricos del *K*-means, y sus pertenencias son grados de afinidad, no probabilidades. En este trabajo cumple el mismo papel que el GMM, ofrecer una segunda lente de asignación blanda con la que confirmar qué jugadores quedan entre dos roles, de modo que un perfil señalado como ambiguo por ambos métodos es una indicación más sólida que si lo marcara solo uno.

3.2. Validación y elección del número de grupos

Todos los métodos de agrupamiento mencionados necesitan que se fije de antemano el número de grupos *k*, y ninguno indica por sí mismo cuál es el más adecuado. En esta sección se reúnen las herramientas usadas para evaluar la calidad de una partición y decidir dicho número. Comenzaremos por los índices internos clásicos, seguiremos con el método CRB-NCE y terminaremos con un análisis de estabilidad *bootstrap*.

3.2.1. Índices clásicos

Estos índices evalúan las particiones sin recurrir a etiquetas verdaderas, basándose exclusivamente en la geometría de los grupos, su compacidad interna y la separación entre ellos. Se calculan para distintos valores de *k* y se escoge aquel que optimiza el índice. Para este trabajo se han usado tres [13].

Silhouette

Para cada observación se comparan la distancia media a las demás observaciones de su propio grupo, a(*i*), y la distancia media a las observaciones del grupo vecino más cercano, *b*(*i*). La silueta de la observación es

$$s(i) = \frac{b(i) - a(i)}{\max\big(a(i), b(i)\big)}$$

y toma valores entre -1 y 1. Valores próximos a 1 indican que la observación está bien asignada, claramente más cerca de su grupo que del vecino, mientras que valores cercanos a 0 o negativos señalan observaciones en la frontera o mal asignadas. La calidad global de la partición se resume con la media de *s*(*i*) sobre todas las observaciones y se elige el *k* que la maximiza.

Índice de Calinski-Harabasz

Compara la dispersión entre grupos con la dispersión dentro de los grupos, dividiendo cada una por sus grados de libertad. Si *c* es el centroide global, c_j el del grupo *j* y n_j su tamaño,

$$CH = \frac{\frac{1}{k-1} \sum_{j=1}^{k} n_j ||c_j - c||^2}{\frac{1}{n-k} \sum_{j=1}^{k} \sum_{x_i \in C_j} ||x_i - c_j||^2}.$$

El numerador es mayor cuanto más separados están los grupos, y el denominador menor cuanto más compactos son, así que un valor alto del índice indica grupos a la vez compactos y bien separados, se elige por tanto el *k* que lo maximiza.

Índice de Davies-Bouldin

Para cada grupo mide su peor emparejamiento, es decir, aquel otro grupo con el que más se confunde. Si s_j es la dispersión media del grupo *j* respecto a su centroide y d_{jl} la distancia entre los centroides de los grupos *j* y *l*, el índice es

$$DB = \frac{1}{k}\sum_{j=1}^{k} \max_{l \neq j} \frac{s_j + s_l}{d_{jl}},$$

donde una pareja de grupos contribuye más cuanto más dispersos son y más cerca están sus centroides. A diferencia de los dos anteriores, conviene minimizarlo, ya que los valores bajos corresponden a grupos compactos y alejados entre sí.

Estos tres índices no siempre coinciden en el *k* que señalan como óptimo, y tienden a premiar particiones con pocos grupos, muy compactas, pero poco informativas. Por este motivo, conviene complementarlos con algún criterio adicional como el método CRB-NCE o el análisis de estabilidad, que veremos a continuación.

3.2.2. Método CRB-NCE

Los índices anteriores devuelven un valor para cada *k* y dejan en manos del analista la elección del número óptimo, algo que en la práctica recuerda al método del codo, es decir, escoger el *k* a partir del cual la inercia deja de bajar de forma apreciable, una decisión a menudo ambigua o fuertemente subjetiva. El método CRB-NCE (*Cohesion Rule-Based Number of Clusters Estimation*) [14] sistematiza esta intuición mediante un enfoque algorítmico basado en reglas de cohesión. En lugar de generar un valor aislado para cada *k*, estima directamente el número óptimo de grupos aplicando un sistema de umbrales sobre la secuencia de una medida de cohesión, como es la suma de cuadrados intra-grupo (SSE).

A partir de la secuencia de SSE, que decrece a medida que se añaden grupos, se calculan las diferencias de primer y segundo orden. La diferencia de primer orden mide cuánto mejora la compacidad interna al pasar de *k* a *k*+1 grupos,

$$\Delta_k^1 = SSE_k - SSE_{k+1}.$$

Por otra parte, la diferencia de segundo orden refleja la desaceleración de dicha mejora a lo largo de la secuencia:

$$\Delta_k^2 = \Delta_{k+1}^1 - \Delta_k^1.$$

La principal innovación del CRB-NCE frente a los métodos de curvatura clásicos radica en el cálculo de las razones de cola (*tail ratios*). A diferencia de los enfoques convencionales, que analizan únicamente las caídas consecutivas, este método compara esa caída con la mayor de las caídas posteriores. De este modo, se define la razón de cola de primer orden (*first-order tail ratio*)

$$TR_k^{\Delta^1} = \frac{\Delta_k^1}{\max_{h>k} \Delta_h^1}.$$

Un valor alto del mismo revela una desaceleración pronunciada, sugiriendo que la magnitud previa a esa caída no vuelve a repetirse en las particiones posteriores.

Para operativizar estas métricas, el procedimiento incorpora tres estimadores combinados, condicionados por dos umbrales de evidencia (δ_1 *y* δ_2) optimizados previamente mediante algoritmos genéticos, garantizando un comportamiento robusto:

- CA + DE (*Combined Argmax + Default Estimator*): se activa automáticamente si las razones de cola de primer orden y segundo orden alcanzan su máximo en la misma partición (condición CA) y, además, el nivel de evidencia de la razón de primer orden supera el umbral δ_1. La estimación es en este caso: $\widehat{K} = k + 1$
- AE (*Alternative Estimator*): si no se cumple alguna de las anteriores condiciones, el algoritmo recorre la secuencia buscando el mayor valor de *k* cuyo *tail ratio* supere el segundo umbral δ_2. En conjuntos de datos con grupos fuertemente solapados, como ocurre al segmentar el rendimiento táctico de los futbolistas, la coincidencia exacta de los máximos tiende a fallar; el estimador AE permite entonces saltar esa limitación e identificar la subestructura latente.
- DE (*Default Estimator*): si ninguna iteración alcanza el nivel de evidencia mínimo requerido por el umbral alternativo, el modelo toma como número óptimo de grupos el que maximiza la razón de cola de primer orden.

$$\widehat{K_{DE}} = \arg\max_k \; TR_k^{\Delta^1} + 1.$$

En este trabajo el CRB-NCE se emplea como criterio adicional para fundamentar la elección del número de grupos, de forma complementaria a los índices clásicos y al análisis de estabilidad. Su lectura confirma la macroestructura que también señalan los primeros, y la elección final se apoya además en la estabilidad y en la interpretabilidad táctica de la partición.

3.2.3. Estabilidad por *bootstrap* y ARI

Los índices clásicos y el CRB-NCE evalúan la calidad de una partición basándose únicamente en su geometría. Sin embargo, algoritmos como *K*-means siempre encontrarán *k* agrupaciones en los datos, incluso si estas carecen de una estructura real o son mero ruido aleatorio. Para garantizar que los roles tácticos descubiertos representan patrones robustos subyacentes es necesario analizar la estabilidad de los grupos. Si una estructura de grupos es genuina, debería mantenerse consistente frente a pequeñas perturbaciones de los datos.

Para introducir estas perturbaciones controladamente se recurre al remuestreo *bootstrap*. Dada la muestra original de *n* observaciones, se generan *B* nuevas muestras aleatorias del mismo tamaño *n*, extrayendo las observaciones con reemplazamiento. Esto implica que en cada muestra *bootstrap*, algunos jugadores aparecerán repetidos mientras que otros quedarán excluidos.

El procedimiento de evaluación de estabilidad consiste en agrupar la muestra original en *k* clústeres y posteriormente repetir este agrupamiento para cada una de las *B* muestras *bootstrap*. Para medir la similitud entre la partición original y las particiones obtenidas tras el remuestreo se usará el Índice de Rand Ajustado (ARI, del inglés *Adjusted Rand Index*) [13].

El índice de Rand (RI) mide la similitud entre dos particiones, *X* e *Y*, considerando todos los pares posibles de observaciones y analizando si se agrupan de la misma manera en ambas. Sea a el número de pares que están en el mismo grupo tanto en *X* como en *Y*, y *b* el número de pares en grupos distintos en ambas particiones. Definimos el Índice de Rand como la proporción de acuerdos sobre el total de pares posibles.

$$RI = \frac{a+b}{\binom{n}{2}}.$$

El problema del índice de Rand es que incluso dos particiones aleatorias obtienen un valor alto, por lo que se corrige restándole el acuerdo esperado por azar y normalizando.

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]}.$$

El Índice de Rand ajustado (ARI) vale 1 cuando ambas particiones son idénticas y se sitúa en torno a 0 cuando la coincidencia no es mejor que la que se esperaría por azar y puede ser incluso negativo.

En la práctica, para un número candidato de grupos *k*, se calcula el ARI entre la partición del conjunto original y la partición generada sobre cada muestra *bootstrap*. Promediando los *B* valores de ARI, se obtiene una métrica global de la fiabilidad de *k*. Un ARI promedio alto certifica que la topología de los datos es robusta, lo que asegura que los roles tácticos detectados reflejan tipologías reales de futbolistas que generalizarán correctamente a otras temporadas o competiciones.

En este trabajo el análisis de estabilidad es la pieza que justifica de forma empírica la elección final del número de grupos. Mientras que los índices clásicos y el CRB-NCE apuntan a una macroestructura gruesa, el ARI medio muestra que la partición más fina en cuatro roles es también altamente reproducible, lo que, unido a su clara interpretabilidad táctica, respalda adoptarla como segmentación definitiva.

3.3. Reducción de dimensionalidad

Trabajar con observaciones descritas por decenas de variables tiene dos consecuencias. La primera es la imposibilidad de visualizar los datos, y con ello de inspeccionar gráficamente la estructura de los grupos. La segunda es la llamada maldición de la dimensionalidad: a medida que crece la dimensión *p*, las distancias entre pares de puntos tienden a uniformizarse y pierden capacidad de discriminar, de modo que los métodos basados en distancias, como el propio *K*-means, se degradan. Para un número moderado de observaciones, dimensiones a partir de algunas decenas ya resultan problemáticas, lo que aconseja reducir la dimensión, o al menos vigilar sus efectos, antes de agrupar. Las técnicas de reducción de dimensionalidad proyectan los datos sobre un espacio de dimensión menor intentando preservar al máximo su estructura, y en este trabajo se emplean con el fin principal de visualizar y validar las particiones. Se consideran tres métodos con filosofías distintas: uno lineal, el análisis de componentes principales, y dos no lineales, t-SNE y UMAP.

3.3.1. Análisis de componentes principales

El PCA es una proyección lineal que busca las direcciones a lo largo de las cuales los datos presentan mayor varianza. La primera componente principal es la dirección que maximiza la varianza de los datos proyectados sobre ella, la segunda la que más varianza recoge entre las ortogonales a la primera, y así sucesivamente. En la práctica los datos deben estandarizarse previamente, pues de lo contrario las variables de mayor escala dominarían las direcciones encontradas. Si X es la matriz de datos estandarizada de n observaciones y p variables, con las observaciones por filas, la matriz de covarianzas muestral, de dimensión $p \times p$, se expresa como

$$C = \frac{1}{n-1} X^T X.$$

Por ser C simétrica y semidefinida positiva, admite una base ortonormal de autovectores con autovalores reales no negativos. Las componentes principales son precisamente esos autovectores ortonormales $v_1, \ldots, v_p$. A cada autovector v_j le corresponde un autovalor λ_j que mide la varianza de los datos proyectados sobre esa dirección, y por convención se ordenan de mayor a menor autovalor, de modo que las primeras componentes son las que recogen mayor variabilidad. La proyección de una observación x sobre la componente j es el producto escalar $\langle x, v_j \rangle$. Conservando las primeras d componentes, con $d \ll p$, se obtiene una representación en $\mathbb{R}^d$ que retiene la mayor parte de la variabilidad global; siendo la proporción de varianza explicada por la componente j igual a $\lambda_j / \Sigma_l \lambda_l$. Su carácter lineal lo hace fiel a la estructura global de los datos, aunque puede no separar bien grupos cuya frontera no es lineal [15].

3.3.2. t-SNE

El t-SNE (*t-distributed stochastic neighbor embedding*) es una técnica no lineal de reducción de dimensionalidad orientada a la visualización, centrada en mantener la estructura local de los datos. En lugar de preservar las distancias globales, traduce las distancias entre puntos en probabilidades de vecindad, de modo que dos observaciones próximas en el espacio original tienen alta probabilidad de ser vecinos, y busca una disposición en dos dimensiones cuyas probabilidades de vecindad se parezcan lo más posible a las originales.

En el espacio original de alta dimensión, t-SNE modela la similitud entre dos observaciones x_i y x_j como una probabilidad condicional basada en una distribución gaussiana centrada en x_i:

$$p_{j|i} = \frac{\exp\left(-||x_i - x_j||^2 / 2\sigma_i^2\right)}{\sum_{k \neq i} \exp(-||x_i - x_k||^2 / 2\sigma_i^2)},$$

donde la varianza σ_i^2 se determina independientemente para cada punto en función de la perplejidad, un parámetro fijado por el usuario que puede interpretarse como el número efectivo de vecinos que se desea considerar alrededor de cada punto: la varianza de cada gaussiana se ajusta para que la distribución de vecindad resultante tenga exactamente esa perplejidad, de modo que los puntos en zonas densas reciben varianzas pequeñas y los de zonas dispersas varianzas mayores. Estas similitudes se simetrizan definiendo una probabilidad conjunta sobre el total de n observaciones:

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}.$$

En el espacio proyectado de baja dimensión, la similitud entre las posiciones y_i e y_j se modela con una distribución t de Student con un grado de libertad, de colas pesadas,

$$q_{ij} = \frac{\left(1 + ||y_i - y_j||^2\right)^{-1}}{\sum_{k \neq l} (1 + ||y_k - y_l||^2)^{-1}}.$$

El uso de una distribución de colas pesadas en baja dimensión resuelve el llamado problema de aglomeración, ya que permite que puntos moderadamente alejados en el espacio original se sitúen cómodamente separados en el plano, evitando que todo se amontone en el centro. Finalmente, el método ajusta las posiciones y_i minimizando la divergencia de Kullback-Leibler entre ambas distribuciones,

$$KL(P|Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}.$$

Los grupos aparecen como nubes bien diferenciadas, pero distorsiona las distancias globales, por lo que la separación o el tamaño relativo entre nubes no debe interpretarse de forma literal. Además, es estocástico, así que distintas ejecuciones pueden dar disposiciones diferentes [16].

3.3.3. UMAP

El UMAP (*uniform manifold approximation and projection*) es otra técnica no lineal fundamentada en ideas de topología [17]. Como el t-SNE, construye similitudes en el espacio original y en el de baja dimensión y busca que ambas concuerden, pero difiere en cómo define esas similitudes y en la función que optimiza.

En el espacio original, para cada punto se consideran sus vecinos más próximos y el peso de la conexión de *i* hacia *j* decae de forma exponencial con la distancia,

$$v_{i\to j} = \exp\left(-\frac{d(x_i, x_j) - \rho_i}{\sigma_i}\right),$$

donde ρ_i es la distancia de x_i a su vecino más cercano, lo que garantiza que cada punto quede conectado al menos con ese vecino, y σ_i es una escala local que se fija de modo que la suma de los pesos de cada punto a sus vecinos sea constante. Estos pesos dirigidos se simetrizan mediante una unión difusa, en lugar de la media que usa el t-SNE,

$$v_{ij} = v_{i\to j} + v_{j\to i} - v_{i\to j} \cdot v_{j\to i}$$

En el espacio proyectado de baja dimensión, el peso entre dos posiciones se modela con un núcleo racional,

$$w_{ij} = \left(1 + a||y_i - y_j||^{2b}\right)^{-1}$$

donde *a* y *b* son parámetros que se ajustan para reproducir una distancia mínima entre puntos. Finalmente, UMAP coloca los puntos minimizando la entropía cruzada entre los pesos del espacio original y los de baja dimensión,

$$C = \sum_{ij}\left[v_{ij}\log\frac{v_{ij}}{w_{ij}} + (1 - v_{ij})\log\frac{1 - v_{ij}}{1 - w_{ij}}\right]$$

La diferencia esencial con el t-SNE está en esa función objetivo. Mientras que el t-SNE minimiza una divergencia que actúa sobre todo atrayendo a los puntos vecinos, la entropía cruzada de UMAP tiene dos términos, uno atractivo que acerca a los puntos conectados en el espacio original y otro repulsivo que separa a los que no lo están. Ese término repulsivo es lo que permite a UMAP conservar mejor la estructura global y, junto con un muestreo eficiente de las repulsiones, lo que lo hace más rápido que el t-SNE. Por eso se emplea como complemento, ya que una separación de roles que se mantiene en ambas proyecciones es una evidencia más sólida que la que ofrece una sola.

3.4. Random forest

El *random forest* es el modelo supervisado sobre el que se construye la valoración. En este trabajo se entrena uno para predecir el rol de cada jugador a partir de sus estadísticas, y son las contribuciones de ese modelo, medidas más adelante con SHAP, las que revelan qué características definen cada rol y sustentan el *rating*. Antes de describir el bosque conviene presentar su pieza básica, el árbol de decisión.

3.4.1. Árboles de decisión

Un árbol de decisión aprende dividiendo repetidamente el conjunto de datos en regiones cada vez más homogéneas. Partiendo de todos los datos, busca la variable y el umbral que mejor separan las clases, divide los datos en dos grupos según ese corte, y repite el proceso en cada grupo, formando una estructura de ramas que termina en hojas. Para predecir la clase de un dato nuevo, se le hace recorrer el árbol según sus valores hasta una hoja, y se le asigna la clase mayoritaria de esa hoja.

El proceso de división no continúa indefinidamente, sino que se detiene mediante criterios de parada, como alcanzar una profundidad máxima, que un nodo contenga menos de un número mínimo de observaciones o que ninguna división posible mejore la homogeneidad por encima de un umbral. Sin tales criterios, el árbol podría crecer hasta aislar cada observación en su propia hoja. La calidad de un corte se mide por cuánto reduce la impureza de los grupos, es decir, cuánto aumenta la homogeneidad con respecto a las clases. La medida de impureza más habitual en clasificación es el índice de Gini, que para un nodo con proporciones p_c de cada clase c es

$$G = 1 - \sum_c p_c^2$$

y vale cero cuando el nodo contiene una sola clase, su máxima pureza, y crece cuanto más mezcladas están las clases. En cada paso, el árbol elige el corte que maximiza la disminución de impureza, que compara la del nodo con la media ponderada de la de sus dos hijos,

$$\Delta G = G - \frac{n_L}{n} G_L - \frac{n_R}{n} G_R$$

donde n_L y n_R son los tamaños de los grupos izquierdo y derecho y n su suma [6].

Los árboles capturan relaciones no lineales e interacciones entre variables sin necesidad de especificarlas, pero son inestables, un pequeño cambio en los datos puede alterar bastante los cortes y producir un árbol muy distinto. Es decir, un árbol individual tiene mucha varianza y tiende a sobreajustar. Esta tendencia se agrava cuanto más profundo se deja crecer el árbol. Con criterios de parada laxos, el árbol acaba memorizando el conjunto de entrenamiento; detener antes su crecimiento reduce la varianza, aunque a costa de un mayor sesgo.

3.4.2. Del árbol al bosque

Random forest corrige esta inestabilidad combinando muchos árboles, y se apoya en dos ideas. La primera es el *bagging* (del inglés *bootstrap aggregating*), que consiste en entrenar cada árbol sobre una muestra *bootstrap* distinta, obtenida remuestreando con reemplazamiento el conjunto original, y agregar después sus predicciones. Como los errores de árboles entrenados sobre muestras distintas tienden a cancelarse al promediarse, el conjunto tiene menos varianza que un árbol solo.

Formalmente, si cada árbol tiene varianza σ^2 y la correlación media entre dos árboles es ρ, la varianza del promedio de B árboles es

$$\rho\sigma^2 + (1 - \rho)\sigma^2/B.$$

Promediar muchos árboles elimina el segundo término, pero no el primero, de modo que la correlación ρ fija el límite de varianza que el promediado puede alcanzar. La segunda idea, característica del *random forest*, es que en cada corte el árbol no considera todas las variables, sino solo un subconjunto aleatorio de ellas. Esto evita que todos los árboles queden dominados por las mismas variables fuertes, los hace más diversos entre sí y, al reducir la

correlación ρ entre ellos, ataca justamente el término que el promediado por sí solo no puede eliminar.

Para clasificar una observación, el bosque combina las predicciones de sus B árboles. Una forma habitual es promediar las probabilidades de clase que estima cada árbol, donde la probabilidad que el árbol b asigna a la clase c en el punto x se estima como la proporción de observaciones de entrenamiento de la clase c presentes en la hoja a la que cae x, y quedarse con la clase más probable,

$$\widehat{p_c}(x) = \frac{1}{B}\sum_{b=1}^{B} p_c^{(b)}(x)$$

donde $p_c^{(b)}(x)$ es la probabilidad que el árbol b asigna a la clase c. El resultado es un modelo robusto y potente, que logra conservar la capacidad de captar relaciones no lineales e interacciones de los árboles, corrigiendo su inestabilidad [18].

En este trabajo se emplea un *random forest* de clasificación que aprende a distinguir los roles a partir de las estadísticas de los jugadores. Se ha preferido a otros modelos potentes, como las redes neuronales, porque capta de forma natural las interacciones entre métricas que caracterizan cada rol, y se combina especialmente bien con el método de interpretabilidad que se usa después, pues existe un algoritmo exacto y eficiente para calcular los valores SHAP sobre conjuntos de árboles, como se verá en la siguiente sección.

3.5. Explicabilidad con SHAP

El *random forest* predice bien los roles, pero es un modelo de caja negra: no es interpretable, en el sentido de que su estructura interna, cientos de árboles combinados, no permite leer directamente por qué asigna una observación a una clase. Conviene distinguir aquí ambas nociones: un modelo es interpretable cuando su propia estructura explica sus predicciones, mientras que la explicabilidad consiste en superponer a un modelo que no lo es un procedimiento externo capaz de explicar sus predicciones sin modificarlo. Ese es el papel de los valores SHAP, un método de atribución que descompone cada predicción del modelo en una suma de contribuciones, una por característica de entrada, asignando a cada una la parte de la predicción que le corresponde. Su fundamento está en los valores de Shapley de la teoría de juegos.

3.5.1. Valores de Shapley

Los valores de Shapley provienen de la teoría de juegos cooperativos [19] y resuelven el problema de repartir de forma justa una ganancia obtenida en común por una coalición de participantes que han contribuido de manera desigual. La idea es medir la aportación de cada participante por su contribución marginal, esto es, cuánto aumenta la ganancia de una coalición cuando ese participante se incorpora, promediada sobre todos los órdenes posibles en que podrían unirse. Para un juego con un conjunto N de n participantes y una función v que asigna a cada coalición $S \subseteq N$ la ganancia que obtiene, el valor de Shapley del participante i es

$$\varphi_i = \sum_{S} \frac{s!\,(n-s-1)!}{n!}\big(v(S\cup\{i\}) - v(S)\big)$$

donde la suma recorre todos los subconjuntos S de participantes que no contienen a i, s es el tamaño de S y $v(S \cup \{i\}) - v(S)$ la contribución marginal del participante i a la coalición S. El factor que multiplica cada contribución es el peso que le corresponde según el número de

órdenes compatibles. Este es el único reparto que cumple que la suma de las aportaciones constituya la ganancia total (eficiencia), que participantes con la misma contribución reciban lo mismo (simetría), que participantes sin aportación no reciban nada y que el reparto de la suma de dos juegos sea la suma de los repartos (aditividad).

3.5.2. SHAP

El método SHAP (del inglés shapley additive explanations) [20] traslada esta idea a la explicación de modelos: trata las características de entrada como los participantes del juego y la predicción del modelo como la ganancia a repartir. El valor SHAP de cada característica es, entonces, su valor de Shapley en ese juego, y mide cuánto empuja la predicción por encima o por debajo de un valor de referencia. Para aplicar la fórmula hay que definir la ganancia $v(S)$ de cada coalición S de características. SHAP la define como la predicción que daría el modelo conociendo únicamente los valores de las características de S; como el modelo requiere todas sus entradas, las ausentes se promedian, lo que equivale a tomar la predicción esperada $v(S) = E[\hat{f}(x) \mid x_s]$. La referencia es la ganancia de la coalición vacía, $v(\emptyset)$, esto es, la predicción media del modelo: lo que cabría esperar sin conocer ninguna característica de la observación. Gracias a la propiedad de eficiencia, la predicción para cualquier observación se descompone de forma exacta como esa referencia más la suma de las contribuciones de todas sus características,

$$f(x) = \varphi_0 + \sum_{i=1}^{n} \varphi_i,$$

donde φ_0 es la predicción media y φ_i el valor SHAP de la característica i. Esta descomposición es la clave de su utilidad, pues permite saber qué métricas y en qué medida llevan al modelo a asignar a un jugador un rol determinado, que es la base del *rating*.

3.5.3. TreeSHAP

Calcular los valores SHAP de forma exacta es, en general, computacionalmente inviable, ya que la definición exige evaluar la ganancia $v(S)$ de los 2^p subconjuntos posibles de características, un coste que crece de forma exponencial con su número. Por ello, los métodos genéricos recurren a aproximaciones por muestreo, con el coste y el error de estimación que ello conlleva.

Para modelos basados en árboles, sin embargo, existe TreeSHAP [21], un algoritmo que calcula los valores SHAP de forma exacta y eficiente explotando la estructura del propio árbol. La clave es doble. En primer lugar, en un árbol la predicción esperada condicionada a una coalición, $E[\hat{f}(x) \mid x_s]$, puede evaluarse con un único recorrido: al llegar a un nodo cuya variable de corte pertenece a S, se desciende por la rama que dictan los valores de x, y si la variable no pertenece a S, se desciende por ambas ramas a la vez, ponderando cada una por la fracción de observaciones de entrenamiento que la siguió. En segundo lugar, TreeSHAP evita repetir ese recorrido para cada coalición. Mediante programación dinámica recorre el árbol una sola vez y mantiene en cada nodo un resumen de todas las coaliciones, agrupadas por tamaño y con los pesos combinatorios que les corresponden en la fórmula de Shapley. Así va acumulando la contribución de cada característica conforme pasa por los nodos que la utilizan.

El resultado es un coste polinómico del orden de $O(T \cdot L \cdot D^2)$, con T árboles, L hojas y profundidad D, frente al coste exponencial del cálculo directo. Para extender el cálculo de un árbol al bosque completo basta la propiedad de aditividad de los valores de Shapley: como la predicción del *random forest* es un promedio de las predicciones de sus árboles, los valores

SHAP del bosque son el promedio de los valores SHAP de cada árbol. Esta es una de las razones por las que se eligió el *random forest*, ya que la combinación de ambos permite obtener explicaciones exactas sin un coste de cálculo prohibitivo. La forma concreta en que estas contribuciones se agregan para construir el *rating* de cada jugador se detalla en el capítulo 4.

3.5.4. Filtrado direccional de SHAP

Hasta aquí, los valores SHAP indican qué características llevan al modelo a asignar una observación a una clase, pero esas contribuciones tienen signo. Una característica puede definir una clase por su presencia, cuando los miembros de la clase destacan por tenerla alta, o por su ausencia, cuando lo que los caracteriza es tenerla baja. Esta distinción es irrelevante para explicar una predicción, pero deja de serlo cuando las contribuciones se emplean como medida de calidad. En el problema de este trabajo, por ejemplo, un delantero de área puede quedar definido en parte por conducir poco el balón; un *rating* que usara directamente todas las contribuciones lo premiaría por no conducir, algo que no tiene sentido, ya que una valoración debe recompensar lo que un jugador hace, no lo que deja de hacer.

El filtrado direccional, que es la aportación metodológica central del trabajo, resuelve esto quedándose solo con las características que definen cada rol por presencia. Para decidirlo, se examina, en cada rol c, la relación entre los valores de cada característica i y sus propias contribuciones SHAP a pertenecer a ese rol, a lo largo de todas las observaciones. Si los valores altos de la característica se asocian a contribuciones SHAP más positivas, el rol se define por su presencia, y si son los valores bajos los que empujan hacia el rol, se define por su ausencia. Esa relación se resume en el signo de la correlación entre ambos,

$$r_i^c = corr(x_i, \varphi_i^c)$$

donde x_i es el vector de valores de la característica i y φ_i^c el de sus contribuciones SHAP hacia el rol c, ambos sobre el conjunto de observaciones. Solo se conservan las características con correlación positiva, es decir, aquellas para las que $r_i^c > 0$, que son las que el rol exige por presencia, y se descartan las de correlación negativa, que lo definirían por ausencia. El *rating* se construye después agregando únicamente esas características conservadas, de modo que la valoración recompensa solo los rasgos que un rol requiere tener. El efecto es doble. Por un lado, la valoración gana sentido futbolístico, ya que ningún jugador puntúa por carecer de algo. Por otro, como se verá en los resultados, el filtrado direccional mejora o mantiene el acuerdo con la valoración experta en la gran mayoría de los roles, lo que respalda empíricamente su utilidad.

4. Desarrollo metodológico

Este capítulo describe en detalle el proceso metodológico completo del sistema, partiendo de las técnicas presentadas en el capítulo anterior. Se expone primero la arquitectura general y, a continuación, cada una de las tres fases con sus decisiones de diseño. La implementación de todo el proceso puede consultarse en el cuaderno de Google Colab [2].

4.1. Arquitectura del sistema

El sistema se organiza en tres fases encadenadas que reproducen el razonamiento de un departamento de *scouting*. Primero se segmenta a los jugadores en roles tácticos, después se valora a cada uno de forma explicable dentro de su rol, y por último se recomiendan jugadores similares a uno dado. La salida de cada fase alimenta a la siguiente, los roles de la Fase 1 son el marco dentro del cual la Fase 2 calcula las valoraciones, y los pesos que la Fase 2 obtiene con SHAP son los que la Fase 3 emplea para medir la similitud. La siguiente figura resume este flujo, desde los datos de partida hasta la validación del sistema.



Figura 1. *Arquitectura del sistema de scouting. Los datos de partida se describen en la sección 2.3, las tres fases centrales constituyen el desarrollo del presente capítulo, y la validación, se aborda en el capítulo 5.*

El punto de partida son los datos y las variables descritos en la sección 2.3. Conviene recordar que el sistema trabaja con 2153 jugadores de las grandes ligas europeas en la temporada 2022/23 y con dos configuraciones de variables en paralelo, una de volumen y otra de ratios. La configuración de volumen está formada por las métricas por noventa minutos y los porcentajes tal como los ofrece la fuente. La de ratios sustituye parte de esas métricas por cocientes que miden eficiencia y tendencia de juego con mayor independencia del estilo del equipo. La siguiente tabla resume los ratios definidos.

Ratio	Definición	Significado
Pase progresivo	Pases progresivos / Pases intentados	Proporción de pases progresivos
Pase al último tercio	Pases al último tercio / Pases intentados	Orientación ofensiva del pase
Pase clave	Pases clave / Pases intentados	Peligro generado por pase
Pase largo	Pases largos completados / Pases intentados	Tendencia al juego largo
Tiro a puerta	Tiros a puerta / Tiros	Puntería
xG por tiro	xG / Tiros	Calidad de las ocasiones
Defensa por toque	(Entradas + Intercepciones) / Toques	Intensidad defensiva por toque
Progresión por toque	Pases progresivos / Toques	Progresión con el balón por toque
Creación por toque	Acciones de creación de tiro / Toques	Creación de ocasiones por toque
Regate por toque	Regates / Toques	Tendencia a regatear

Tabla 1. *Ratios derivados que componen la configuración de ratios, con su definición y su significado.*

Tras esta preparación se aplica la última etapa del preprocesamiento, que adapta la escala de las variables a cada tarea. Para el agrupamiento y el cálculo de distancias, todas las variables se estandarizan, es decir, se transforman para que tengan media cero y desviación típica uno, restando la media μ y dividiendo por la desviación típica σ de cada variable,

$$x_i^z = \frac{x_i - \mu}{\sigma},$$

La puntuación *z* (*z-score*) resultante expresa cada valor como su distancia a la media medida en desviaciones típicas, de modo que un valor positivo indica un rendimiento por encima de la media de la muestra y uno negativo por debajo. No queda acotada a un rango fijo, pero centra las variables y las hace comparables en varianza, que es justo lo que necesitan tanto el *K*-means, al basarse en distancias euclídeas, como el análisis de componentes principales. Por ese motivo todas las variables se estandarizan antes del agrupamiento.

4.2. Fase 1. Segmentación por roles

La primera fase agrupa a los jugadores en roles tácticos. Como se argumentó en la introducción, la posición sobre el papel no equivale al rol que un jugador desempeña de verdad, así que el objetivo es descubrir esos roles a partir de los datos, sin imponerlos de antemano. Para ello se recurre al aprendizaje no supervisado, en concreto al agrupamiento.

4.2.1. División por líneas y doble configuración

Inicialmente, los jugadores se reparten en tres líneas según su posición principal, defensas, centrocampistas y delanteros, dejando fuera a los porteros, cuyas estadísticas son de naturaleza distinta. La razón de esta división previa es que agrupar a todos los jugadores a la vez se limitaría a recuperar la separación evidente entre líneas, mientras que agrupar dentro de cada línea es donde emergen los matices interesantes y los subroles. La línea actúa así como una partición gruesa y conocida que el agrupamiento refina en roles.

Dentro de cada línea, el agrupamiento se ejecuta dos veces en paralelo, una por cada configuración de variables descrita en la sección 2.3, la de volumen y la de ratios. Esto proporciona dos lecturas complementarias de la misma realidad y ambas se mantienen a lo largo de todo el análisis para poder compararlas.

4.2.2. Agrupamiento y elección del número de roles

El algoritmo de agrupamiento empleado es *K*-means (sección 3.1.1). La elección se basa en su sencillez y eficiencia, por su correcta adaptación al espacio de variables estandarizadas y, sobre todo, porque sus centroides ofrecen un prototipo interpretable de cada rol, lo que resulta clave para etiquetarlos después.

Este algoritmo exige fijar de antemano el número de grupos *k*. Para elegirlo se aplica el conjunto de herramientas de validación de la sección 3.2, los índices clásicos, el método CRB-NCE y el análisis de estabilidad por *bootstrap*. Estas herramientas apuntan a una macroestructura gruesa, una división dual de cada línea (separando roles defensivos y ofensivos), pero se adopta una partición más fina en cuatro roles por línea, que sigue siendo estable y ofrece una granularidad táctica más rica y útil para el *scouting*. La justificación detallada de esta decisión, con los valores concretos de cada criterio, se presenta en el capítulo 5.

4.2.3. Tratamiento de la ambigüedad

K-means asigna cada jugador a un único rol de forma tajante, pero las fronteras entre roles futbolísticos son difusas y muchos jugadores se sitúan a caballo entre varias de ellas. Para

capturar esa ambigüedad, se ejecutan dos métodos de asignación blanda complementarios, GMM (sección 3.1.2) y el *fuzzy c-means* (sección 3.1.3). El primero asigna a cada jugador una probabilidad de pertenecer a cada rol, y el segundo un grado de pertenencia. Cuando ninguno de esos valores domina con claridad, el jugador se marca como ambiguo. Para que las etiquetas de los tres métodos sean comparables, los grupos de las asignaciones blandas se alinean previamente con los de *K*-means. Los jugadores ambiguos concretos, su análisis y su confirmación visual mediante t-SNE y UMAP se analizan en el capítulo 5.

4.2.4. Etiquetado de roles

Los grupos que devuelve *K*-means son simples números sin significado. Para que el sistema sea útil, cada grupo se interpreta y recibe una etiqueta táctica. Con este propósito se examina el centroide de cada grupo, es decir, qué métricas son característicamente altas o bajas en él, y se traduce ese perfil a un rol futbolístico reconocible. Así, por ejemplo, un grupo de defensas dominado por despejes y duelos aéreos ganados se etiqueta como centrales contundentes. Este etiquetado se realiza para cada línea y cada configuración, y el conjunto completo de roles obtenidos se resume en el capítulo 5.

Con los jugadores ya segmentados y sus roles etiquetados, se dispone de la información necesaria para pasar a la fase de valoración.

4.3. Fase 2. Valoración explicable

Una vez segmentados los jugadores, la segunda fase asigna a cada uno una valoración que refleja cómo de bien desempeña las funciones propias de su rol, y lo hace de forma explicable. Toda esta fase se apoya en el *random forest* y en los valores SHAP presentados en las secciones 3.4 y 3.5.

4.3.1. Modelo de clasificación y obtención de los pesos

Para cada línea y cada configuración se entrena un *random forest* de clasificación, con quinientos árboles y clases equilibradas, que aprende a predecir el rol de cada jugador a partir de sus variables estandarizadas. Conviene subrayar que el modelo no se entrena para predecir roles nuevos, pues los roles ya se conocen de la fase anterior, sino como vehículo para extraer, mediante SHAP, qué características definen cada rol. Aplicando TreeSHAP sobre el bosque se obtienen, para cada rol y cada característica, dos cantidades. La primera es su importancia, medida como la media del valor absoluto de sus contribuciones SHAP, que indica cuánto pesa esa característica en la definición del rol. La segunda es su dirección, el signo de la correlación descrito arriba, que indica si el rol se define por la presencia o por la ausencia de esa característica.

4.3.2. Construcción del *rating*

Cada característica se transforma en su percentil dentro del rol, de cero a cien. Para una variable con observaciones $x_1, \ldots, x_n$ dentro de un rol, el percentil de un valor x_i es

$$\mathrm{perc}(x_i) = \frac{100}{n} \left|\{ j : x_j \leq x_i \}\right|$$

Esta transformación tiene tres ventajas que la hacen idónea para construir un sistema de valoración. Unifica todas las métricas en una escala común de cero a cien, es robusta frente a valores extremos al apoyarse en el orden y no en la magnitud, y resulta inmediata de interpretar, ya que un percentil de noventa significa que el jugador rinde en esa métrica por encima del noventa por ciento de sus comparables. En el sistema de valoración los percentiles

se calculan dentro de cada rol, de manera que cada jugador se compara con sus pares tácticos y no con toda la línea.

De este modo, el valor de un jugador se lee como su posición relativa entre los demás jugadores de su mismo rol. El *rating* de un jugador es entonces una media ponderada de sus percentiles en las características seleccionadas, con pesos dados por las importancias SHAP normalizadas,

$$R = \sum_i \widehat{w_i}\, p_i$$

donde p_i es el percentil del jugador en la característica i dentro de su rol y $\hat{w}_i$ el peso normalizado de esa característica. En la práctica se emplean las doce características de mayor importancia. Las características que se incluyen en esa suma es justo lo que distingue a los distintos enfoques de valoración.

4.3.3. Los cinco enfoques de valoración

Se han construido cinco variantes del *rating*, que comparten la mecánica anterior y se diferencian en qué características usan y de dónde salen sus pesos.

1. **SHAP ingenuo**: emplea las 12 características más importantes según SHAP con independencia de su dirección, mezclando así las de presencia y las de ausencia. Sirve de referencia de partida para medir el efecto del filtrado.
2. **SHAP direccional:** emplea solo las características de dirección positiva, las que definen el rol por presencia. Es el *rating* de referencia del sistema y la materialización de la aportación central.
3. **Experto:** sustituye los pesos SHAP por unos pesos asignados manualmente a partir de conocimiento futbolístico. Para que sea comparable con el direccional, esos pesos se aplican sobre el mismo conjunto de características que utiliza este. Los pesos asignados a cada métrica se recogen en el Anexo C (tabla 13). Ponderar las métricas según el rol es habitual en la evaluación de jugadores basada en datos [22].
4. **Híbrido**: combina a partes iguales el SHAP direccional y el experto, equilibrando la valoración basada en los datos con el criterio humano,

$$R_{\text{híbrido}} = 0{,}5 \cdot R_{\text{direccional}} + 0{,}5 \cdot R_{\text{experto}}$$

5. **Jerárquico**: combina dos niveles de valoración. Junto al *rating* específico del rol, el SHAP direccional, se calcula un *rating Core* a nivel de línea, que mide la calidad general del jugador dentro de toda su línea, por ejemplo, entre todos los centrocampistas, en lugar de dentro de su rol concreto. Para obtener este *rating Core* aplicamos el mismo procedimiento SHAP utilizando como etiquetas las tres líneas principales (defensas, centrocampistas y delanteros). El jerárquico los combina dando más peso al específico,

$$R_{\text{jerárquico}} = 0{,}3 \cdot R_{\text{core}} + 0{,}7 \cdot R_{\text{direccional}}$$

   de manera que un jugador se valora sobre todo por lo bien que cumple en su rol, sin perder de vista su nivel general en la línea.

La comparación entre estos enfoques, y en particular la mejora que aporta el filtrado direccional frente al ingenuo se aborda en el capítulo 5.

4.4. Fase 3. Recomendador de fichajes

Dado un jugador objetivo, el recomendador devuelve los jugadores más parecidos a él, para lo que necesita medir cuán similares son dos jugadores a partir de sus estadísticas. La medida

de partida más natural es la distancia euclídea, la longitud del segmento que los separa en el espacio de características,

$$d(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$$

donde x_i e y_i son los valores de la característica i en cada jugador. Como las variables están previamente estandarizadas, las diferencias $x_i - y_i$ son comparables entre métricas de distinta escala. El problema de esta distancia es que trata todas las variables por igual, cuando para un rol dado no todas importan lo mismo. Dos delanteros pueden diferir mucho en una métrica defensiva irrelevante para su rol y, aun así, ser muy parecidos en lo que de verdad lo define. Para corregirlo se emplea una distancia euclídea ponderada, que asigna a cada variable un peso según su relevancia,

$$d(i, j) = \sqrt{\sum_f w_f \left(x_{i,f} - x_{j,f}\right)^2}$$

donde w_f es el peso de la característica f. La clave del recomendador está en de dónde salen esos pesos. En lugar de fijarlos a mano, se toman de los valores SHAP calculados en la Fase 2, de modo que cada variable pesa tanto como contribuye a definir el rol del jugador objetivo: las diferencias en las métricas que caracterizan ese rol cuentan mucho en la distancia, y las irrelevantes apenas influyen. Los pesos se normalizan para que sumen uno, con lo que la distancia es una media ponderada de las diferencias al cuadrado y resulta comparable entre roles.

4.4.1. Los tres modos de recomendación

El recomendador ofrece tres modos, que se diferencian en los pesos que usan y en el conjunto de candidatos sobre el que buscan.

1. **Modo global:** usa un único conjunto de pesos común a toda la línea, obtenido combinando las importancias SHAP de todos sus roles. Una variable pesa más cuanto más relevante es para caracterizar a los jugadores de esa línea en su conjunto, sin mirar a ningún rol en particular. Además, la búsqueda no se restringe al rol del jugador objetivo, sino que recorre a todos los jugadores de la línea, de modo que los parecidos que devuelve pueden ser de su mismo rol o de otro distinto. Es, por tanto, la búsqueda más amplia de las tres, útil cuando no se quiere encajonar la comparación dentro de un solo rol.
2. **Modo por rol**: pondera por los valores SHAP del rol concreto del jugador objetivo, sin filtrar por signo, y restringe los candidatos a los jugadores de ese mismo rol. Mide así la similitud dentro de un rol, pero usando tanto los rasgos de presencia como los de ausencia que lo caracterizan.
3. **Modo por rol direccional**: pondera únicamente por las variables de dirección positiva del rol, las que lo definen por presencia, y también restringe los candidatos al mismo rol. Es la extensión propuesta en este trabajo, ya que calcula la similitud sobre lo que hace bueno a un jugador en su rol, y no sobre lo que comparte por carencia. Dos jugadores se consideran parecidos si coinciden en lo que su rol exige tener.

4.4.2. Coherencia con la valoración

Los modos del recomendador no usan pesos nuevos, sino exactamente los mismos que los *ratings* de la Fase 2. El modo por rol emplea los pesos del *rating* SHAP ingenuo, y el modo

por rol direccional los del *rating* SHAP direccional. De este modo, las tres fases del sistema comparten una única fuente de pesos, los valores SHAP, lo que permite una lectura unificada de todo el sistema, desde la definición de los roles hasta el recomendador de fichajes.

4.4.3. Filtros de uso práctico

A la búsqueda por similitud se le añaden filtros opcionales pensados para el uso real en *scouting*, como acotar la edad de los candidatos, para buscar por ejemplo solo relevos jóvenes, o excluir a los jugadores del mismo club que el objetivo. Estos filtros no alteran el cálculo de la distancia, solo restringen el conjunto de candidatos sobre el que se aplica.

Con esto queda definido el sistema completo. Su comportamiento sobre casos reales, las recomendaciones concretas que produce y su validación se presentan en el siguiente capítulo.

5. Resultados y validación del sistema

Este capítulo presenta y discute los resultados del sistema sobre los datos de la temporada 2022/23, siguiendo el mismo orden de las fases: la segmentación, la valoración y el recomendador, y cierra con las validaciones externa y predictiva. Todos los resultados pueden reproducirse con el cuaderno de Google Colab [2].

5.1. Resultados de la segmentación

Se analiza primero la decisión estructural más importante de la segmentación, el número de roles por línea, y después los roles obtenidos, su composición y los casos ambiguos.

5.1.1. Elección del número de roles

El número de roles K no se decide con un único criterio, sino combinando las tres herramientas de la sección 3.2, los índices internos clásicos, el método CRB-NCE y el análisis de estabilidad por *bootstrap*. Como ninguno por separado es concluyente cuando los grupos se solapan, se realiza un análisis conjunto, atendiendo no solo al óptimo global de cada criterio, sino también a sus máximos locales.

El óptimo global de todos los criterios apunta a K=2. La tabla 2 muestra la evolución de los tres índices clásicos y de la razón de cola del CRB-NCE con el número de grupos, para cada línea.

Línea	Configuración	Silhouette	CH	DB	CRB-NCE
Centrocampistas	volumen	2	2	2	2
Centrocampistas	ratios	2	2	2	2
Defensas	volumen	2	2	**6**	2
Defensas	ratios	2	2	2	2
Delanteros	volumen	2	2	2	2
Delanteros	ratios	2	2	**3**	**3**

Tabla 2. *Número óptimo de grupos señalado por cada criterio interno (Silhouette, CH, DB) y por el CRB-NCE, en cada línea y configuración. Salvo tres excepciones (en negrita), todos convergen en K = 2, la macroestructura.*

Los índices clásicos resultan poco informativos más allá de ese óptimo, ya que la silueta y el índice de Calinski-Harabasz decrecen de forma monótona desde K=2, y el de Davies-Bouldin alcanza su mejor valor también en K=2, salvo dos excepciones aisladas. No presentan, por tanto, ningún máximo local intermedio, su mejor número de grupos es siempre el menor posible, y no ayudan a detectar una estructura más fina.

El método CRB-NCE sí aporta información en este punto. La figura 2 muestra la evolución de su razón de cola con el número de grupos, para cada línea.

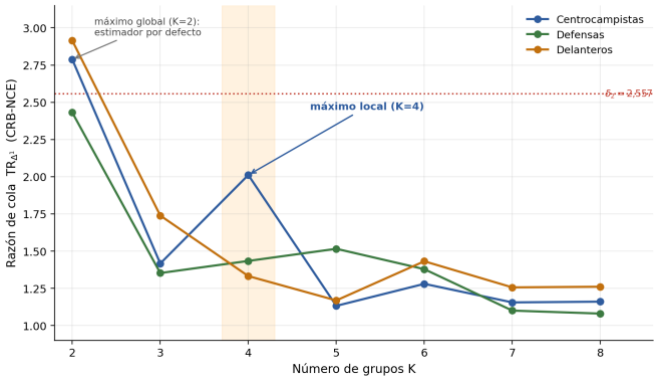


Figura 2. *Evolución de la razón de cola de primer orden del CRB-NCE (TR_Δ^1) con el número de grupos K, por línea, en la configuración de volumen. El máximo global coincide con K=2 en las tres líneas, el estimador por defecto del método, mientras que los máximos locales secundarios, el más nítido en centrocampistas en K=4, revelan una subestructura más fina. En rojo, el umbral δ_2 del método.*

Aunque su máximo global, el estimador por defecto, se sitúa también en *K*=2, en delanteros-ratios en *K*=3, la razón presenta máximos locales secundarios que señalan una subestructura. El caso más nítido es el de los centrocampistas en volumen, donde la razón de cola repunta en *K*=4 (2,01) muy por encima de sus valores vecinos (1,42 en *K*=3 y 1,13 en *K*=5). Como se explicó en la sección 3.2.2, esos máximos locales son precisamente la señal que el método está pensado para capturar mediante su estimador alternativo en datos con grupos solapados, y apuntan a que, más allá de la división dual, existe una partición más detallada en torno a cuatro grupos.

Para confirmar que esa subestructura es fiable se recurre al análisis de estabilidad por *bootstrap*. La figura 3 muestra el ARI medio entre las particiones de las submuestras frente al número de grupos. La partición en cuatro roles se mantiene reproducible en las seis combinaciones de línea y configuración, con valores de ARI iguales o superiores a 0,66, antes de que la estabilidad caiga con claridad al pasar a cinco o más grupos. *K*=4 es, por tanto, una subestructura real y estable, y no ruido.

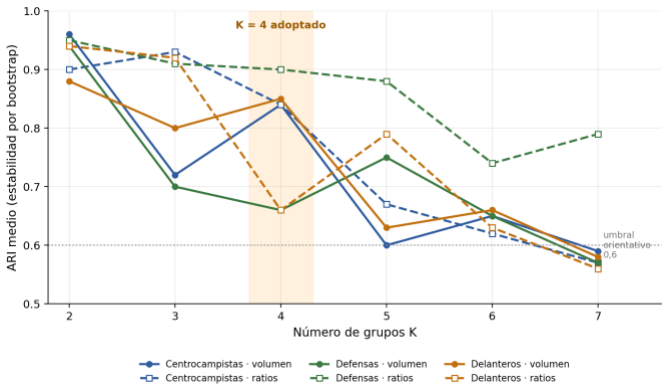


Figura 3. *Estabilidad de la segmentación (ARI medio por bootstrap) frente al número de grupos K, en cada línea y configuración. La partición en K = 4 se mantiene reproducible (ARI ≥ 0,66) antes de la clara caída a partir de K = 5.*

Por todo ello se adopta *K*=4 en las tres líneas, lo que ofrece una segmentación rica y homogénea, con cuatro roles por línea, sin sacrificar la reproducibilidad.

Conviene detenerse en los delanteros, la línea donde la elección de *K*=4 frente a *K*=3 es menos evidente en estabilidad y merece, por tanto, justificación. El examen de los grupos muestra que el cuarto rol aporta una distinción tácticamente muy valiosa. Con tres grupos, el clúster de perfiles no finalizadores agrupa dos tipos de extremos muy distintos bajo una

misma etiqueta, los que destacan por su trabajo defensivo y los que lo hacen por regate y creación por banda. Al pasar a cuatro grupos, esos dos perfiles se separan en grupos semánticamente distintos, los extremos trabajadores, de perfil de contención (Luiz Henrique, Ayoze, Jesús Navas), y los extremos de desequilibrio, definidos por el regate y la creación por toque (Nico Williams, Ocampos, Papu Gómez). Los roles de 9 de área y de creadores puros, en cambio, se mantienen bien definidos en ambas resoluciones. Esta diferenciación es clave para el *scouting*, pues responde a necesidades de fichaje muy distintas, y es esta ganancia semántica la que justifica adoptar K=4 pese a su leve coste en reproducibilidad. El resto de las decisiones combina el criterio estadístico y semántico.

5.1.2. Los roles identificados

Con K=4, la segmentación produce cuatro roles en cada línea, doce en total. Cada uno recibe una etiqueta táctica a partir de las métricas que dominan su centroide, según el criterio visto en el etiquetado de roles de la sección 4.2.4. La tabla 3 recoge los doce roles de la configuración de ratios, la principal, con las métricas que los definen y algunos jugadores representativos. La configuración de volumen reproduce las mismas familias de rol en centrocampistas y defensas, y difiere algo en delanteros, lo que se analiza en la sección 5.1.3.

Rol	Métricas que lo definen	Ejemplos
Centrocampistas		
Mediocentros defensivos	Entradas, intercepciones, despejes y recuperaciones	Fabinho, De Roon, Tameze
Organizadores de posesión	Progresión y pase al último tercio por toque, precisión de pase	Rakitić, Mason Mount, Ramsey
Creadores élite	Asistencias esperadas, creación de tiro y de gol, pases clave	Trossard, Brandt, Pedro Gonçalves
Atacantes / extremos	Creación de tiro por toque, tiros a puerta, goles esperados, regate	Léo Baptistão, Ljubicic
Defensas		
Centrales contundentes	Despejes, duelos aéreos ganados, pase largo, goles esperados en contra	Eric Dier, Lienhart, Idzes
Centrales con salida	Pases al último tercio, precisión de pase y de pase largo	Lenglet, Kalulu, Marušić
Laterales creadores	Creación de tiro por toque, asistencias esperadas, pases clave	Dumfries, Mæhle, Miranda
Laterales generalistas	Centros al área, entradas ganadas, regate	Ashley Young, Matty Cash, Rico Henry
Delanteros		
9 de área	Duelos aéreos ganados, goles esperados, xG por tiro, goles	Vlahović, En-Nesyri, Borja Iglesias
Creadores puros	Creación de tiro, asistencias esperadas, pases clave y al área	Benzema, Vinícius, Dembélé
Extremos de desequilibrio	Regate y creación de tiro por toque	Nico Williams, Ocampos, Papu Gómez
Extremos trabajadores	Entradas más intercepciones, intercepciones, recuperaciones, bloqueos	Luiz Henrique, Ayoze, Jesús Navas

Tabla 3. *Los doce roles identificados (cuatro por línea) en la configuración de ratios, con las métricas que dominan su perfil y algunos jugadores representativos.*

Los roles obtenidos tienen una clara validez aparente, ya que se corresponden con arquetipos futbolísticos reconocibles. En los centrocampistas aparecen el mediocentro de corte, el organizador, el creador y el llegador. En los defensas se separan los dos perfiles de central, el contundente y el de salida, de los dos de lateral, el creador y el generalista. En los delanteros conviven el rematador de área, el creador puro y los dos perfiles de extremo, el desequilibrante y el trabajador, cuya distinción ya se discutió al justificar K=4. Que un método no supervisado, sin ninguna noción previa de táctica, recupere estas categorías es en sí mismo un primer indicio de que la segmentación captura una estructura real.

5.1.3. Volumen vs ratios

Las dos configuraciones se ejecutaron en paralelo, según la sección 4.2.1, y cabe preguntarse hasta qué punto producen la misma segmentación o lecturas distintas. Para medirlo se calcula el ARI entre la partición de volumen y la de ratios en cada línea. Los valores son moderados o bajos en las tres, 0,37 en centrocampistas, 0,28 en defensas y 0,54 en delanteros, lo que indica que las dos configuraciones no son redundantes, sino que asignan los roles de forma apreciablemente distinta. Son, por tanto, dos lentes complementarias y no dos copias de la misma información.

El contraste entre líneas es revelador. La coincidencia es más baja en defensas y centrocampistas y más alta en delanteros, y la razón está en lo que captura cada configuración. El volumen refleja qué hace un jugador en el contexto de su equipo, y ese contexto pesa mucho en las líneas más atrasadas. Un central o un mediocentro de un equipo dominador acumula muchos toques y pases por el simple hecho de que su equipo domina el balón, con independencia de su rol. Los ratios, al medir eficiencia y tendencia mediante cocientes, depuran ese efecto de estilo de equipo. Por eso en defensas y centrocampistas las dos lentes divergen tanto, una está teñida por el estilo del equipo y la otra no. En los delanteros, en cambio, el volumen de finalización y la eficiencia finalizadora van más de la mano, y las dos configuraciones convergen algo más.

Esta divergencia, lejos de ser un problema, justifica mantener ambas configuraciones, ya que cada una responde a una pregunta distinta de *scouting*. La de volumen es más adecuada para encontrar a quien desempeña un rol en un tipo concreto de equipo, mientras que la de ratios identifica un perfil de habilidad con mayor independencia del equipo en el que juega.

5.1.4. Análisis de ambigüedad

K-means asigna cada jugador a un único rol de forma tajante, pero los modelos de asignación blanda permiten medir cómo de clara es esa asignación. Se emplean dos niveles de análisis. Uno amplio, que señala a los jugadores cuya probabilidad máxima de pertenencia no es rotunda, por debajo de 0,85, y que sirve para constatar lo escasos que son. Y otro estricto y tácticamente más relevante, que se centra en los jugadores genuinamente disputados entre dos roles, aquellos cuya segunda probabilidad de pertenencia supera el 40% de la primera.

Una primera mirada la ofrece la proyección PCA de los centrocampistas en volumen, la línea con más casos ambiguos, en la que se resaltan y etiquetan los jugadores de baja certeza (figura 4). Aun siendo la línea más poblada de ambigüedad, el panorama salta a la vista, la gran mayoría de los jugadores se agrupa con nitidez en torno a su rol y solo un puñado, marcado

y nombrado sobre la proyección, queda en las zonas de frontera entre grupos.

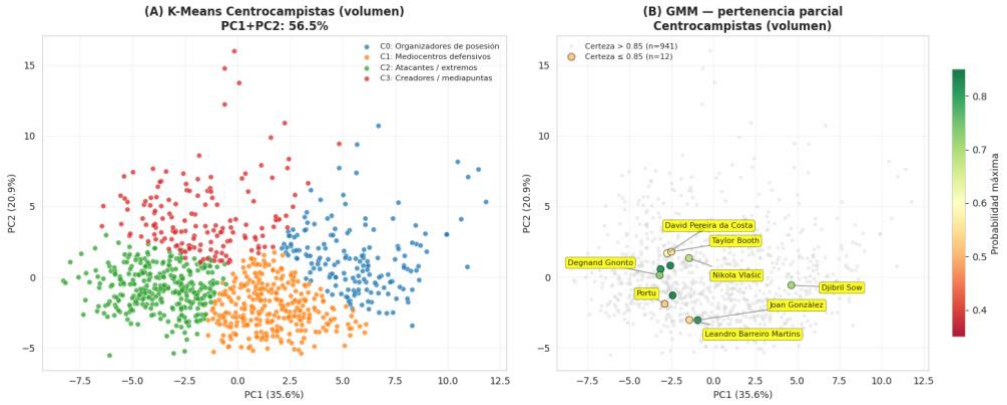


Figura 4. *Proyección PCA de los centrocampistas en la configuración de volumen. El panel izquierdo muestra los cuatro roles según K-means y el derecho resalta y etiqueta a los jugadores de baja certeza de pertenencia (probabilidad máxima inferior a 0,85), entre ellos Portu, sobre el resto de la muestra en gris. Pese a ser la línea con más casos ambiguos, estos son escasos, lo que evidencia que las fronteras entre roles están bien definidas.*

Los números lo confirman. Con el criterio estricto solo trece jugadores resultan ambiguos en todo el conjunto, menos del uno por ciento de cada línea. Que el modelo de mixtura gaussiana, mucho más flexible, converja casi siempre a asignaciones de alta certeza valida el uso de *K*-means como método principal, ya que su restricción de asignación binaria no introduce distorsión apreciable en la práctica totalidad de los casos.

Esos pocos casos, además, no se reparten al azar, sino que siguen un gradiente muy claro por línea, recogido en la tabla 4.

Línea	Volumen	Ratios	Total
Centrocampistas	6	3	9
Defensas	3	1	4
Delanteros	0	0	0
Total	**9**	**4**	**13**

Tabla 4. *Número de jugadores ambiguos (segunda probabilidad de pertenencia superior al 40% de la primera) por línea y configuración. La ambigüedad sigue un gradiente decreciente de centrocampistas a delanteros.*

Se concentran en los centrocampistas, con seis casos en volumen y tres en ratios, descienden en los defensas, con tres y uno, y desaparecen por completo en los delanteros. Este patrón reproduce con exactitud la estructura continua frente a discreta de cada línea, la ambigüedad es máxima donde las fronteras entre roles son más difusas, los centrocampistas, y nula donde están mejor definidas, los delanteros.

Las proyecciones no lineales t-SNE y UMAP ilustran esos dos extremos (figura 10, en el anexo B). Dos detalles refuerzan la lectura. Los jugadores situados en las zonas de transición de estas proyecciones coinciden con los que el modelo de mixtura gaussiana marca como ambiguos, y los patrones de t-SNE y UMAP coinciden entre sí, lo que indica una estructura real en los datos y no un artefacto de una proyección concreta.

Merece la pena diseccionar el caso más ambiguo de todos, el de Portu, del Getafe. *K*-means lo asigna al rol de atacantes/extremos, pero el modelo de mixtura gaussiana reparte su pertenencia casi a partes iguales, un 52% a ese rol y un 48% al de mediocentros defensivos. El grado de pertenencia *fuzzy* es aún más elocuente, ya que se distribuye entre tres roles sin

que ninguno alcance siquiera un tercio. La comparación de sus métricas con las medias de los dos roles en disputa explica el reparto. Portu tiene el volumen de tiro propio de un atacante, pero su producción final, los goles, los goles esperados y las acciones de creación de gol, se queda muy por debajo de ese rol y lo arrima al perfil del mediocentro. Es, en suma, un atacante por intención, pero no por rendimiento, un jugador que dispara como un extremo pero finaliza como un centrocampista, y al que por eso ningún rol captura del todo. Su radar *fuzzy* frente a *K*-means (figura 11, en el anexo B) hace visible ese reparto, con un perfil que no se ciñe a un único rol, sino que se estira entre varios.

Por último, para caracterizar de un vistazo cada uno de los roles obtenidos, los radares por rol resumen el perfil medio de cada grupo en sus métricas más representativas (figura 8, en el anexo B). Cada radar muestra la firma estadística de un rol, los despejes y duelos aéreos que distinguen al central contundente, las acciones de creación del creador élite o los goles esperados del 9 de área, y permite comparar visualmente unos roles con otros dentro de cada línea.

El análisis de la ambigüedad arroja, en conjunto, una conclusión doble. La estructura continua de los centrocampistas justifica complementar *K*-means con la asignación blanda del modelo de mixtura gaussiana y del *fuzzy*, que capturan una información que una partición dura no puede. Y, al mismo tiempo, la escasez de casos ambiguos valida a *K*-means como método de asignación principal, ya que para la inmensa mayoría de los jugadores el rol es inequívoco.

5.2. Resultados de la valoración

Esta sección evalúa la segunda fase del sistema. Primero se mide el efecto del filtrado direccional, la aportación central del trabajo, sobre el acuerdo con la valoración experta, y a continuación se examinan los *ratings* que el sistema produce y su utilidad para el *scouting*.

5.2.1. Impacto del filtrado direccional

Esta sección evalúa la aportación central del trabajo, comprobar si el filtrado direccional produce realmente una mejor valoración. Para la primera validación se lleva a cabo una comparación frente a la valoración experta. Como se explicó en la sección 4.3.3, el *rating* experto pondera las características con pesos asignados a mano a partir de conocimiento futbolístico, de modo que medir cuánto se le parece un *rating* basado en datos equivale a medir cuánto reproduce el juicio táctico de un experto. La comparación se hace mediante la correlación de Spearman dentro de cada uno de los veinticuatro clústeres, los cuatro roles de cada una de las tres líneas en las dos configuraciones, enfrentando el *rating* SHAP ingenuo y el SHAP direccional contra el experto. Los pesos SHAP direccionales obtenidos para cada rol se recogen en el Anexo C (tabla 14).

El resultado respalda con claridad el método. El filtrado direccional mejora o mantiene el acuerdo con el experto en veintiuno de los veinticuatro clústeres (figura 5). De ellos, diecisiete mejoran de forma efectiva, cuatro se mantienen igual, que son los roles cuyas características definitorias ya eran todas de presencia, de modo que el *rating* ingenuo y el direccional coinciden, y solo tres empeoran, todos de forma marginal, como mucho 0,07, y dos de ellos en roles que el *rating* ingenuo ya capturaba casi a la perfección.

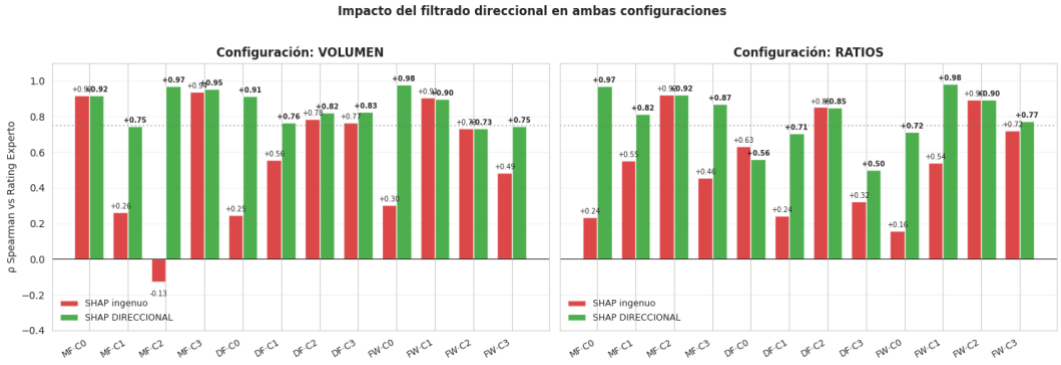


Figura 5. *Acuerdo con la valoración experta (correlación de Spearman) del rating SHAP ingenuo frente al SHAP direccional, en cada uno de los veinticuatro clústeres, separados por configuración. El filtrado direccional (verde) iguala o supera al ingenuo (rojo) en veintiuno de los veinticuatro, con las mayores mejoras en los roles definidos en parte por ausencia de acciones.*

Lo más revelador es dónde se concentran las grandes mejoras, precisamente en los roles que se definen en parte por la ausencia de ciertas acciones, que es donde el SHAP ingenuo fracasa. El caso más extremo es el de los atacantes/extremos en volumen, donde la correlación con el experto pasa de ligeramente negativa, con un valor de −0,13, a casi perfecta, 0,97. El *rating* ingenuo llegaba a premiar la ausencia de determinadas acciones, invirtiendo el orden lógico, y el filtrado direccional lo corrige por completo. La misma transformación se repite en los mediocentros defensivos en ratios (de 0,24 a 0,97), en los centrales contundentes en volumen (de 0,25 a 0,91) y en los nueves de área (de 0,31 a 0,98 en volumen y de 0,54 a 0,98 en ratios). En todos ellos el *rating* salta de un acuerdo débil, o incluso inverso, a un acuerdo casi total con el criterio experto.

El rol de 9 de área ilustra bien el mecanismo (figura 6). Un rematador de área se define en parte por lo que no hace, no crea apenas juego ni regatea, de modo que el SHAP ingenuo, al incluir esas características de ausencia, recompensaba a un jugador por no crear y por no regatear, algo que nada tiene que ver con su calidad como finalizador. El filtrado direccional se queda solo con las características de presencia, los goles esperados, la finalización y el juego aéreo, y con ello el *rating* se ordena igual que el del experto.

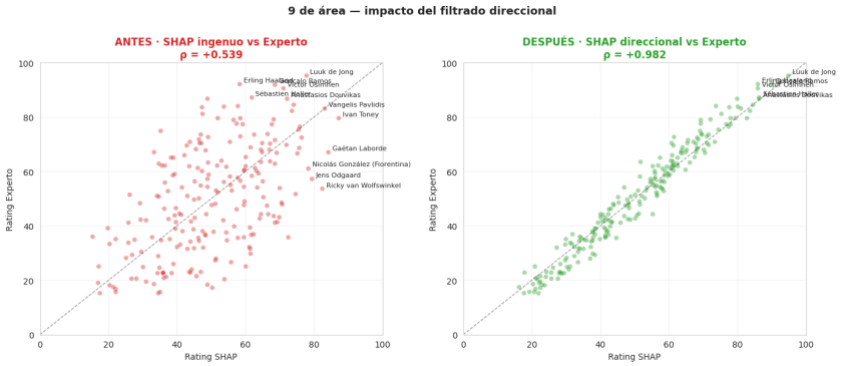


Figura 6. *Relación entre el rating y la valoración experta en el rol de 9 de área (ratios), antes (SHAP ingenuo) y después (SHAP direccional) del filtrado. Cada punto es un jugador y la diagonal marca el acuerdo perfecto. El filtrado eleva la correlación de Spearman de 0,54 a 0,98.*

Las tres caídas, en cambio, son intrascendentes. Se dan en roles que el *rating* ingenuo ya capturaba bien, donde el margen de mejora era nulo y el filtrado introduce solo una variación despreciable. Ninguna supera 0,07.

En conjunto, la evidencia sostiene la tesis central del trabajo. Conservar únicamente la aportación direccional positiva produce un *rating* más alineado con la valoración táctica

experta, sin penalizar a los especialistas por aquello que su rol no exige. La mejora es sistemática y mayor justo donde el enfoque ingenuo más falla, en los roles definidos por ausencia.

5.2.2. *Ratings* resultantes

Más allá de coincidir con el experto, el *rating* debe producir clasificaciones con sentido y, sobre todo de cara al *scouting*, sacar a la luz a jugadores valiosos poco conocidos. Examinar el top-10 de cada rol según el *rating* direccional confirma ambas cosas.

Tómese el rol de mediocentros defensivos (tabla 5). La clasificación incluye, como cabría esperar, a nombres consagrados como Casemiro, Declan Rice o João Palhinha, lo que confirma la validez aparente del *rating*, ya que el sistema coloca arriba a élites reconocidas. Pero junto a ellos aparecen jugadores mucho menos mediáticos que puntúan igual o más alto, como Andrei Girotto, del Nantes, que encabeza el rol, o Loreintz Rosier, del Estoril, y el joven Lucien Agoume, del Troyes. Son precisamente estos jugadores los que dan valor al sistema, perfiles estadísticamente equivalentes a la élite en su rol, pero lejos del foco mediático.

Jugador	Equipo	Edad	R. direccional	R. experto
Andrei Girotto	Nantes	30	87,8	84,4
Benjamin André	Lille	31	85,3	89,6
Guido Rodríguez	Betis	28	83,6	84,2
Ellyes Skhiri	Köln	27	82,5	88,8
Casemiro	Manchester Utd	30	82,2	85,9
Morten Hjulmand	Lecce	23	81,5	83,0
João Palhinha	Fulham	27	81,2	85,3
Loreintz Rosier	Estoril	24	80,7	81,3
Lucien Agoume	Troyes	20	80,1	80,7
Declan Rice	West Ham	23	80,0	81,0

Tabla 5. *Top-10 del rol de mediocentros defensivos (ratios) según el rating direccional, con el rating experto para comparar. Junto a élites reconocidas (Casemiro, Rice, Palhinha) aparecen perfiles poco mediáticos con puntuaciones equivalentes (Girotto, Rosier, Agoume), que son los de mayor interés para el scouting.*

El patrón se repite en los demás roles. Entre los organizadores de posesión, el top lo lideran nombres reconocibles como Dani Ceballos, Modrić, Kroos, Pedri o Frenkie de Jong, pero también asoma un André Horta, del Braga, mucho menos conocido.

Esa doble composición, jugadores de renombre que confirman que el *rating* es sólido y desconocidos que ofrecen oportunidades de mercado, es justo lo que debe producir una herramienta de *scouting*. Un *rating* que solo recuperase a los famosos sería una clasificación redundante, mientras que uno que destapa a desconocidos estadísticamente comparables resulta de verdad útil.

5.2.3. *Rating* específico vs *Rating core*

De los cinco enfoques de *rating* de la sección 4.3.3, el jerárquico combina dos niveles, el *rating* específico del rol, que es el direccional, y el *rating* Core, que mide la calidad del jugador respecto a toda su línea. Compararlos muestra que responden a preguntas distintas y que el jerárquico equilibra ambas.

Los dos *ratings* están correlacionados, pero divergen (figura 9, en el anexo B). Un jugador puede dominar un rol muy concreto sin ser igual de sobresaliente para el conjunto de su línea, y al revés. El caso de los mediocentros defensivos lo ilustra bien. Andrei Girotto encabeza el *rating* específico del rol, pero, al ser un especialista puro, su *rating* Core es más bajo, de modo que el *rating* jerárquico lo modera. En cambio, jugadores que destacan también en el conjunto de la línea, como Casemiro o Declan Rice, mantienen mejor su posición en el jerárquico.

Esto dota al sistema de dos lentes complementarias. El *rating* direccional responde a quién es el mejor en un rol concreto, ideal para buscar un especialista, mientras que el jerárquico responde a quién es el mejor para la línea poniendo el acento en el rol, útil cuando interesa una mayor polivalencia. El ojeador dispone de ambas según lo que busque.

5.3. Resultados del recomendador

El recomendador se evalúa de forma cualitativa, comprobando si sus recomendaciones tienen sentido futbolístico sobre casos reales y conocidos. Todos los ejemplos emplean el modo por rol direccional, la extensión propuesta en este trabajo, que mide la similitud sobre lo que define a un rol por presencia.

El primer caso busca un relevo joven para Sergio Busquets, filtrando por edad igual o inferior a 25 años y excluyendo a jugadores de su propio club, lo que ilustra de paso los filtros prácticos de la sección 4.4.3. El sistema lo identifica como mediocentro defensivo y devuelve en cabeza a Mats Wieffer y a Martín Zubimendi, dos pivotes de corte y distribución que responden con exactitud al perfil que se busca como heredero de un organizador defensivo (tabla 9, en el anexo B). En el caso de Zubimendi, fue uno de los nombres más sonados a la salida de Busquets del Barça. La lista continúa con nombres del mismo molde, como Ibrahim Sangaré o Salis Abdul Samed, todos centrocampistas de equilibrio y salida.

El segundo caso parte de Erling Haaland, a quien el sistema sitúa en el rol de 9 de área. Sus jugadores más próximos son Victor Osimhen, Robert Lewandowski, Loïs Openda, Wissam Ben Yedder o Santiago Giménez entre los primeros (tabla 10, en el anexo B). El recomendador recupera con limpieza el arquetipo del delantero de área, sin colar perfiles de otra naturaleza.

El tercer caso es el más contundente. Al buscar similares a Iñigo Martínez, central con salida, el sistema devuelve a Daniel Vivian como mejor coincidencia, y lo hace en las dos configuraciones, volumen y ratios, y además con un margen amplio sobre el resto (tabla 6). Que el primer resultado sea idéntico y dominante bajo dos conjuntos de variables independientes es una señal fuerte de la consistencia del recomendador. El detalle lo redondea, ya que Vivian es compañero de Iñigo en el Athletic y su relevo natural en el eje de la defensa, justo lo que un ojeador concluiría a mano.

	Volumen		Ratios	
#	**Jugador**	**Sim.**	**Jugador**	**Sim.**
1	**Daniel Vivian**	79,1	**Daniel Vivian**	71,3
2	Miguel Araujo	75,5	Diogo Leite	71,0
3	Andrei Girotto	74,0	Cenk Özkacar	70,6
4	Nehuén Pérez	72,7	Josuha Guilavogui	69,2
5	Yeray Álvarez	72,0	Mario Hermoso	65,3
6	Fabian Schär	70,7	Fernando Calero	65,2

Tabla 6. *Jugadores más similares a Iñigo Martínez, central con salida, en modo direccional y en las dos configuraciones. Daniel Vivian es la primera coincidencia en ambas, lo que evidencia la robustez del recomendador.*

En conjunto, estos casos muestran que el recomendador produce sugerencias con un sentido futbolístico claro, recupera arquetipos reconocibles y, en el caso de Iñigo y Vivian, ofrece un resultado robusto frente al cambio de configuración. El modo direccional concentra la similitud en lo que hace bueno a un jugador en su rol, y es eso lo que da coherencia a las recomendaciones.

5.4. Validación externa con valor de mercado

La validación interna de la sección 5.2 comparó el *rating* con el juicio de un experto. Una validación externa lo enfrenta a una referencia independiente, la valoración que el mercado hace de los jugadores, tomada de Transfermarkt.

La hipótesis es que un buen *rating* debería guardar relación con lo que el mercado paga. Lo relevante en esa comparación no es que ambas magnitudes coincidan en escala, sino que ordenen a los jugadores de forma parecida, esto es, que un jugador mejor valorado por el modelo tienda a estarlo también por el mercado. Por ello se emplea la correlación de Spearman, que mide la fuerza de la relación entre dos variables calculando la correlación de Pearson sobre sus rangos en lugar de sobre sus valores. Cuando no hay empates, admite la expresión

$$\rho = 1 - \frac{6 \sum_i d_i^2}{n(n^2 - 1)}$$

donde d_i es la diferencia entre los rangos que ocupa el jugador i en las dos ordenaciones y n el número de jugadores. Toma valores entre −1 y 1, con 1 cuando ambas ordenaciones coinciden por completo. Se prefiere a la correlación de Pearson porque no exige que la relación sea lineal, basta con que sea creciente, y porque es robusta frente a valores atípicos y a la escala sesgada de los valores de mercado.

En este caso se comparan el *rating* direccional y el logaritmo del valor de mercado de cada jugador, tomado de Transfermarkt.

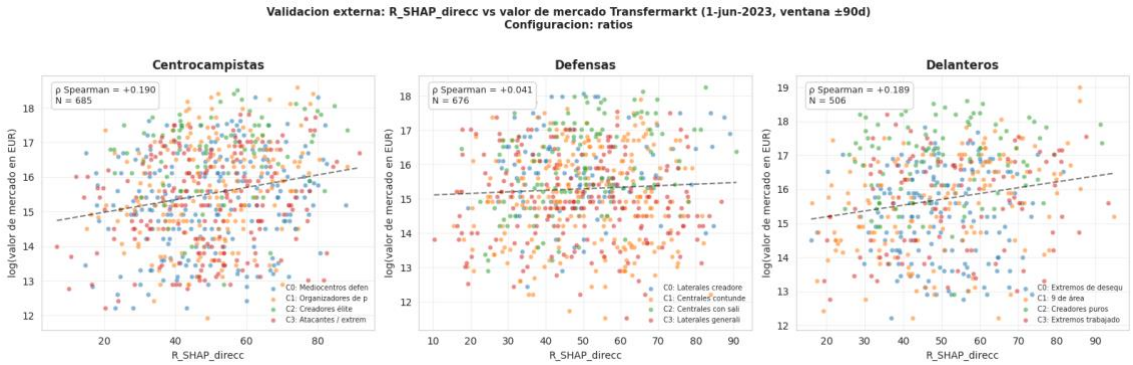


Figura 7. *Relación entre el rating direccional y el logaritmo del valor de mercado, por línea, con cada rol en un color y la recta de ajuste global. La nube es difusa, coherente con una correlación modesta, y algo más marcada en los roles medibles.*

Las correlaciones globales por línea son modestas, en torno a 0,19 en centrocampistas y delanteros, y casi nula en defensas (tabla 7). El diagrama de dispersión de la figura 7 lo refleja, una nube difusa con una leve tendencia ascendente. Lejos de ser un problema, es lo esperable, ya que el valor de mercado depende de muchos factores ajenos al rendimiento estadístico en un rol, como la edad, el club, la reputación o el atractivo comercial. Una correlación perfecta sería, de hecho, indeseable, porque significaría que el mercado ya pone precio a todo lo que el *rating* capta, sin dejar margen para la ventaja en el *scouting*.

La señal interesante aparece al bajar al nivel de rol. La correlación es claramente más alta en los roles más medibles, aquellos cuya producción definitoria es concreta y cuantificable, el 9 de área (0,37) y los centrales con salida (0,35). En ellos, lo que hace bueno a un jugador, los goles y el juego aéreo en el primero, el pase y la progresión en el segundo, es justo lo que el mercado también ve y paga. En cambio, la correlación es casi nula o negativa en los roles más intangibles, como los laterales creadores (0,01), los centrales contundentes (0,02), los laterales generalistas (−0,07) o los extremos de desequilibrio (0,03), perfiles cuyo valor se fija por aspectos que las estadísticas capturan peor o que dependen del contexto.

Un detalle refuerza el enfoque por roles. En los defensas, la correlación del conjunto de la línea es prácticamente nula (0,04), y sin embargo dentro de ella los centrales con salida alcanzan 0,35. La segmentación por roles destapa así una relación que el análisis a nivel de línea habría ocultado.

Rol	N	ρ
Centrocampistas		
Toda la línea	685	**0,19**
Mediocentros defensivos	221	0,18
Organizadores de posesión	196	0,23
Creadores élite	78	0,22
Atacantes / extremos	190	0,14
Defensas		
Toda la línea	676	**0,04**
Laterales creadores	105	0,01
Centrales contundentes	249	0,02
Centrales con salida	126	**0,35**
Laterales generalistas	196	−0,07
Delanteros		
Toda la línea	506	**0,19**
Extremos de desequilibrio	155	0,03
9 de área	157	**0,37**
Creadores puros	95	0,17
Extremos trabajadores	99	0,14

Tabla 7. *Correlación de Spearman entre el rating direccional y el logaritmo del valor de mercado, por línea y rol (configuración de ratios). La relación es mayor en los roles más medibles (9 de área y centrales con salida, en negrita).*

La distancia entre el *rating* y el valor de mercado es, precisamente, la oportunidad de *scouting*. Para localizarla se emplea un modelo de regresión lineal, que expresa una variable respuesta como combinación lineal de varias variables explicativas más un término de error, ajustando los coeficientes por mínimos cuadrados, esto es, minimizando la suma de los residuos al cuadrado [6]. Dentro de cada rol se modela el *rating* del jugador en función de su valor de mercado, su edad y el nivel de su club,

$$R = \beta_0 + \beta_1 \, log(V) + \beta_2 E + \beta_3 E^2 + \beta_4 T + \varepsilon$$

donde R es la valoración, V el valor de mercado, E la edad, T un indicador de pertenencia a un club de primer nivel y ε el error. El valor de mercado entra en logaritmo porque su distribución es muy asimétrica, con unos pocos jugadores que valen mucho más que la

mayoría. La edad, su cuadrado y el indicador de club actúan como controles, el término cuadrático recoge que la relación con la edad no es lineal y el indicador de club la prima que los grandes clubes pagan al margen del rendimiento. Estos controles evitan señalar como infravalorados a jugadores cuyo desajuste se explica solo por la edad o el prestigio de su equipo. El ajuste del modelo y la significatividad de los coeficientes se detallan en el Anexo D (tabla 15 y figura 12).

La pieza clave es el residuo, la diferencia entre la valoración real de un jugador y la que el modelo predice a partir de su valor, su edad y su club. Un residuo positivo grande identifica a un jugador cuya valoración supera con claridad la esperada para su precio, su edad y su club, esto es, un candidato a estar infravalorado, con buen rendimiento aún no reflejado en el mercado. De forma simétrica, un residuo muy negativo señala a un jugador sobrevalorado.

Los jugadores con mayor residuo positivo son, por tanto, aquellos a quienes el sistema valora alto pero el mercado paga barato (tabla 8). Entre los mediocentros defensivos, esos infravalorados son, de nuevo, Andrei Girotto, Loreintz Rosier o Lucien Agoume, los mismos nombres poco mediáticos que encabezaban el *rating* en la sección 5.2.2, confirmados ahora como infravalorados respecto al mercado.

Jugador	Equipo	Edad	*Rating*	Residuo	Valor (M€)
Loreintz Rosier	Estoril	24	80,7	+35,4	1
Andrei Girotto	Nantes	30	87,8	+34,3	4
Lucien Agoume	Troyes	20	80,1	+33,9	7
Morten Hjulmand	Lecce	23	81,5	+29,1	15
Ryan Flamingo	Vitesse	20	72,0	+28,9	2,5

Tabla 8. *Jugadores más infravalorados en el rol de mediocentros defensivos, según el residuo del modelo rating ~ log(valor) + edad + edad² + club. Un residuo positivo alto indica un rating muy superior al que sugieren su valor, edad y club.*

El sistema también identifica el caso contrario. Los residuos más negativos señalan a jugadores sobrevalorados, cuyo rendimiento estadístico queda por debajo de lo que su precio, su edad y su club harían esperar (tabla 11, en el anexo B). El patrón es coherente con la intuición futbolística. Entre los centrocampistas aparece Yves Bissouma (Tottenham), un fichaje caro, dieciocho millones, cuyo *rating* direccional queda muy por debajo del esperado para ese precio, reflejo de una temporada de bajo protagonismo. En defensa destaca Reinildo Mandava (Atlético de Madrid), valorado en veinticinco millones pero con una producción ofensiva que el *rating*, centrado en métricas de aportación, apenas recompensa. Y entre los delanteros sobresale Brennan Johnson (Nottingham Forest), cuyos treinta y ocho millones de valor contrastan con un rendimiento estadístico modesto en su rol.

Conviene leer estos casos con cautela. Un residuo negativo no implica que el jugador sea malo, sino que su valor de mercado responde a factores que el *rating* no captura: la proyección de futuro de un jugador joven, el caso de Johnson; la solidez defensiva sin reflejo en las métricas de aportación, el de Mandava; o sencillamente la expectativa que el mercado deposita en un fichaje reciente, el de Bissouma. El sistema no pretende corregir al mercado, sino señalar dónde su valoración y el rendimiento medible divergen, en una dirección o en la otra.

La validación externa resulta, así, doblemente informativa. Donde el valor es estadísticamente legible, en los roles medibles, el *rating* sigue al mercado, lo que confirma que capta valor real. Y donde se separa de él, señala jugadores infravalorados concretos, que

es justo el uso para el que el sistema está pensado. El objetivo del *rating* no es replicar el precio de mercado, sino encontrar dónde se le puede ganar.

5.5. Validación predictiva: el mercado de invierno

La validación más exigente consiste en comprobar si el sistema, alimentado solo con datos de la primera vuelta, habría señalado como valiosos a los jugadores que de hecho se ficharon en el mercado de invierno de esa misma temporada. A diferencia de las anteriores, esta validación es de naturaleza predictiva: el sistema no conoce los traspasos y se le pide, a posteriori, que los evalúe.

El procedimiento aprovecha una particularidad del conjunto de datos. Los jugadores transferidos en el mercado de invierno que superaron los novecientos minutos en ambos clubes aparecen en FBref con una fila por club; aunque en el sistema principal se agregaron en un único registro, aquí se recuperan sus datos del club de origen, es decir, su rendimiento en la primera mitad de la temporada, antes del traspaso. La hipótesis es directa: si el sistema asigna un *rating* alto a un jugador basándose solo en esa primera vuelta, y poco después un club de mayor nivel lo ficha, el *rating* habrá anticipado una decisión real de *scouting*.

Para ello se calcula el *rating* de cada jugador transferido con exactamente el mismo método que el sistema principal, percentil dentro de su rol ponderado por las importancias SHAP direccionales, pero usando únicamente sus estadísticas en el club de origen. La dirección de cada traspaso se fijó manualmente a partir de fuentes públicas, ya que los datos automáticos de transferencias presentaban lagunas en el mercado de invierno; el contraste cubre veinte traspasos con dirección verificada, tras excluir de forma automática siete casos de homonimia.

Los resultados respaldan la hipótesis. En lo más alto del *rating* de origen aparecen los fichajes más destacados del mercado invernal: Cody Gakpo (94,1), que pasó del PSV al Liverpool; Pedro Porro (88,2), del Sporting de Portugal al Tottenham; y Enzo Fernández (73,0), del Benfica al Chelsea en el que fue el traspaso más caro de la ventana (tabla 12, en el anexo B). En los tres casos, un rendimiento estadístico sobresaliente en la primera vuelta precedió a un fichaje por un club de mayor nivel, justo el patrón que una herramienta de *scouting* debería anticipar.

Igual de informativo es el extremo opuesto de la tabla. Los movimientos que no responden a un salto de nivel por rendimiento reciben *ratings* de origen bajos: cesiones como la de João Cancelo (Manchester City a Bayern de Múnich), traspasos a equipos en apuros como el de Weston McKennie (Juventus a Leeds) o jugadores en mala racha como Francesco Caputo. El sistema, por tanto, no solo destaca los fichajes de mejora, sino que los distingue de los movimientos laterales o forzados.

Conviene, no obstante, leer este contraste con cautela. No todos los traspasos de invierno obedecen a la misma lógica, hay cesiones, decisiones tácticas o motivos económicos ajenos al rendimiento, por lo que esta validación se presenta como evidencia cualitativa y complementaria, no como una prueba estadística formal. Aun así, que los fichajes más sonados de la ventana encabecen el *rating* de origen y que las cesiones y movimientos forzados queden en la parte baja constituye una señal favorable sobre la utilidad práctica del sistema, y cierra el bloque de validación enlazando el rendimiento medido con las decisiones reales del mercado.

6. Conclusiones

Este trabajo ha diseñado, implementado y validado un sistema completo de *scouting* de futbolistas construido íntegramente sobre datos públicos. El sistema encadena tres fases, segmentación por roles, valoración explicable y recomendación de fichajes, sobre 2153 jugadores de las siete grandes ligas europeas en la temporada 2022/23, descritos mediante dos configuraciones de variables que se mantienen en paralelo durante todo el análisis.

La segmentación ha mostrado que los roles tácticos pueden descubrirse a partir del rendimiento sin recurrir a las etiquetas de posición. La partición en cuatro roles por línea resulta estable y futbolísticamente legible, la doble configuración de volumen y ratios ofrece lecturas complementarias de la misma realidad, y los métodos de asignación blanda identifican de forma consistente a los jugadores de perfil ambiguo, que son precisamente los más interesantes de matizar en un contexto de *scouting*.

La aportación metodológica central, el filtrado direccional de las contribuciones SHAP, ha quedado respaldada empíricamente: mejora o mantiene el acuerdo con la valoración experta en veintiuno de los veinticuatro roles analizados, y produce ordenaciones con sentido futbolístico, capaces de destacar perfiles valiosos y poco mediáticos que un *rating* sin filtrar premiaría por razones equivocadas. El sistema de valoración resultante es, además, transparente por construcción, pues cada *rating* puede descomponerse en las características concretas que lo sustentan.

Las validaciones externa y predictiva sitúan al sistema frente a referencias independientes. La correlación con el valor de mercado es alta justo donde cabía esperarla, en los roles de producción más medible, y baja donde el precio depende de factores que las estadísticas capturan peor, y es precisamente esa divergencia la que el sistema explota para señalar jugadores infravalorados concretos. El contraste con los traspasos reales del mercado de invierno muestra, además, capacidad de anticipación al mercado, que es en última instancia el propósito de una herramienta de *scouting*.

El trabajo tiene limitaciones que conviene hacer explícitas. Se apoya en una única temporada, por lo que no captura la evolución de los jugadores ni la estabilidad temporal de los roles. Emplea estadísticas de eventos, que describen lo que un jugador hace con y cerca del balón, pero no su comportamiento sin él, algo que requeriría datos de seguimiento. El etiquetado de los roles, aunque guiado por los centroides, conserva un componente de juicio futbolístico, y el valor de mercado usado como referencia externa es, en sí mismo, una medida imperfecta del rendimiento. Del mismo modo, los pesos del *rating* experto son inevitablemente subjetivos, a pesar de estar fijados a partir de la literatura de *scouting,* otra elección razonable podría alterar las valoraciones expertas.

Estas limitaciones marcan las líneas futuras más naturales: extender el análisis a varias temporadas para estudiar trayectorias y proyectar a jugadores jóvenes, incorporar datos de seguimiento que enriquezcan la descripción de los roles, aprender de los propios datos la combinación del *rating* direccional con el criterio experto, y llevar el sistema a una interfaz utilizable por un departamento de *scouting* real. El marco construido, con una única fuente de pesos que recorre la segmentación, la valoración y la recomendación, está pensado para admitir esas extensiones sin alterar su arquitectura.

Bibliografía

[1] Biermann, C. (2019). Football Hackers: The Science and Art of a Data Revolution. Blink Publishing.

[2] Mosquera Taboada, Á. (2026). TFG_Colab_final_J [cuaderno de código]. Google Colab. https://drive.google.com/file/d/1mwgxHSneHzG22-Xiz9vHNL_W8C88K11V/view?usp=sharing

[3] IBM. ¿Qué es el machine learning (ML)? IBM Think. https://www.ibm.com/mx-es/think/topics/machine-learning

[4] StarTechUp. La historia del machine learning. https://www.startechup.com/es/blog/machine-learning-history/

[5] IBM. El futuro de la inteligencia artificial. IBM Think Insights. https://www.ibm.com/es-es/think/insights/artificial-intelligence-future

[6] Hastie, T., Tibshirani, R. y Friedman, J. (2009). The Elements of Statistical Learning. https://hastie.su.domains/ElemStatLearn/

[7] FBref. Football Statistics and History. https://fbref.com/en/

[8] Rábanos, F. LanusStats [software]. GitHub. https://github.com/federicorabanos/LanusStats

[9] Lanus Stats. Cómo scrapear Fbref con Python para obtener estadísticas de fútbol gratis [vídeo]. Youtube. https://www.youtube.com/watch?v=_PNAMPo9QOY

[10] scikit-learn. Clustering: K-means. https://scikit-learn.org/stable/modules/clustering.html#k-means

[11] scikit-learn. Gaussian mixture models. https://scikit-learn.org/stable/modules/mixture.html

[12] scikit-fuzzy. Módulo clúster: fuzzy c-means clustering. https://scikit-fuzzy.github.io/scikit-fuzzy/auto_examples/plot_cmeans.html

[13] scikit-learn. Clustering performance evaluation. https://scikit-learn.org/stable/modules/clustering.html#clustering-performance-evaluation

[14] Rodríguez, J. T., Gonzalez-Garcia, X., Gómez, D. y Bustince, H. (2026). CRB-NCE: An adaptable cohesion rule-based approach to number of clusters estimation. Pattern Recognition. https://doi.org/10.1016/j.patcog.2025.112909

[15] scikit-learn. Decomposing signals in components: PCA. https://scikit-learn.org/stable/modules/decomposition.html#pca

[16] scikit-learn. Manifold learning: t-SNE. https://scikit-learn.org/stable/modules/manifold.html#t-sne

[17] McInnes, L., Healy, J. y Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv. https://arxiv.org/abs/1802.03426

[18] scikit-learn. Ensemble methods: forests of randomized trees. https://scikit-learn.org/stable/modules/ensemble.html#forests-of-randomized-trees

[19] Molnar, C. (2025). Shapley Values. En Interpretable Machine Learning. https://christophm.github.io/interpretable-ml-book/shapley.html

[20] Lundberg, S. M. y Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. arXiv. https://arxiv.org/abs/1705.07874

[21] Lundberg, S. M., Erion, G. G. y Lee, S.-I. (2018). Consistent Individualized Feature Attribution for Tree Ensembles. arXiv. https://arxiv.org/abs/1802.03888

[22] Pappalardo, L., Cintia, P., Ferragina, P., Massucco, E., Pedreschi, D. y Giannotti, F. (2019). PlayeRank: data-driven performance evaluation and player ranking in soccer via a machine learning approach. ACM Transactions on Intelligent Systems and Technology, 10(5), art. 59. https://arxiv.org/abs/1802.04987

Anexo A. Variables del conjunto de datos

Este anexo ofrece una muestra del aspecto final del conjunto de datos, una vez aplicado el procesamiento descrito en la sección 2.3.2. El sistema trabaja con dos configuraciones paralelas de variables, una de volumen y otra de ratios, con 42 y 43 variables respectivamente. A modo ilustrativo se reproduce a continuación una selección de filas y columnas de la configuración de volumen, repartida en dos bloques por motivos de espacio: el primero recoge los identificadores y las métricas de ataque y pase, y el segundo, las de creación, acciones defensivas, conducción y juego aéreo. La relación de variables de la configuración de ratios coincide con la recogida en la tabla 1 del capítulo 4.

Player	Gls/90	xG/90	Ast/90	xA/90	Sh/90	PassesCompleted/90	Passes%
Sergio Canales	0.15	0.16	0.11	0.16	1.42	36	75.70
William Carvalho	0.11	0.11	0.04	0.06	0.96	45.76	86.50
Nabil Fekir	0.19	0.23	0.19	0.16	2.25	25.20	78.10
Luiz Felipe	0	0.01	0	0.01	0.15	32.74	85.20
Édgar González	0	0.06	0	0.03	0.46	31.68	88.80
Andrés Guardado	0.07	0.02	0.07	0.04	0.52	28.42	84.90

Tabla A.1. Muestra del conjunto de datos final (configuración de volumen). Bloque 1: identificación, ataque y pase.

Bloque 2: creación de ocasiones, acciones defensivas, conducción y juego aéreo (mismos jugadores).

Player	KP/90	PrgDistPasses/90	Tkl+Int/90	Clr/90	Recov/90	Dribbles/90	Touches/90	Aerial%
Sergio Canales	1.81	144.87	1.26	0.26	3.90	0.90	54.10	35.10
William Carvalho	0.67	226.73	1.79	0.67	4.82	0.88	59.97	54.20
Nabil Fekir	1.53	91.13	0.80	0	2.07	1.13	40.47	42.10
Luiz Felipe	0.13	223.17	2.70	4.61	3.48	0.22	49.09	46.30
Édgar González	0.08	199.92	1.96	4.80	3.32	0.08	44.24	59.30
Andrés Guardado	0.46	153.65	2.46	1.12	4.65	0.19	39.31	37

La muestra completa consta de 42 variables por jugador; aquí se reproduce una selección representativa. Todas las métricas están expresadas por noventa minutos, salvo las terminadas en %, que son porcentajes. El conjunto final excluye a los porteros, cuyo rendimiento se describe con métricas específicas no comparables con las del resto de posiciones.

Anexo B. Resultados detallados

Este anexo reúne resultados complementarios que no son imprescindibles para seguir el argumento del capítulo 5 y que se referencian desde el texto donde corresponde: figuras de apoyo de la segmentación y de la valoración, y dos ejemplos adicionales del recomendador de fichajes.

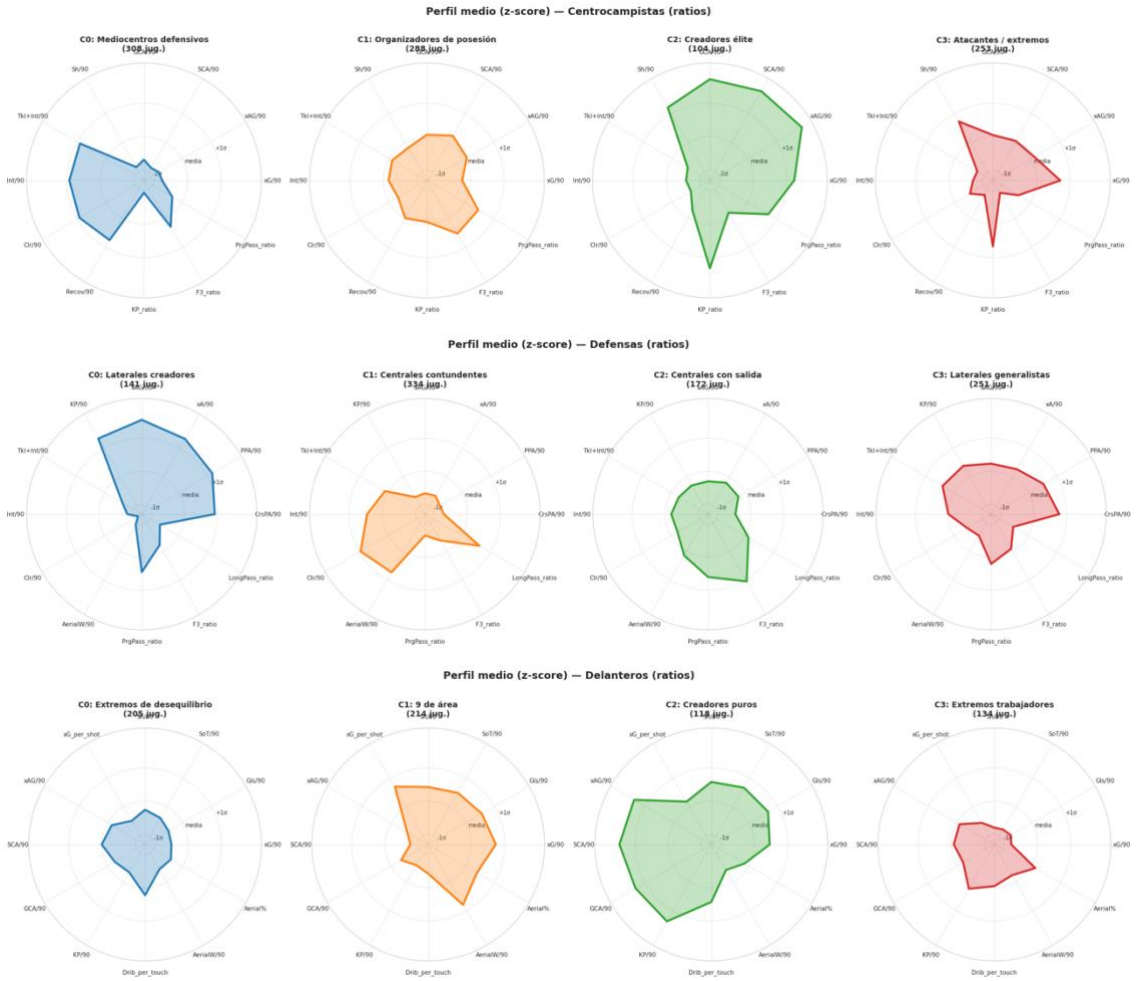


Figura 8. *Radares de los cuatro roles de cada línea en la configuración de ratios, cada uno con el perfil medio del rol en sus métricas más representativas. Permiten comparar de un vistazo la firma estadística de los distintos roles dentro de una misma línea.*

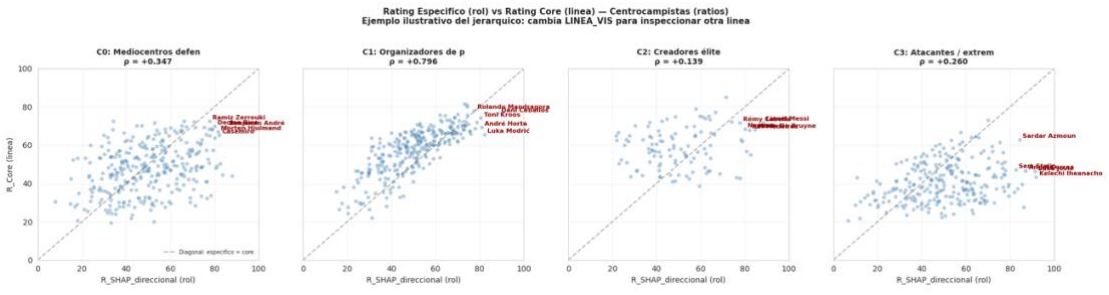


Figura 9. *Relación entre el rating específico del rol (direccional) y el rating Core de línea, por rol, en los centrocampistas (ratios). Los jugadores por encima de la diagonal destacan más para el conjunto de la línea que en su rol concreto, y a la inversa. El rating jerárquico pondera ambos niveles.*



Figura 10. *Proyecciones t-SNE y UMAP de dos casos representativos. Los defensas en ratios ilustran una estructura discreta, con sus cuatro roles separados con nitidez en dos macrobloques, los dos perfiles de central frente a los dos de lateral. Los centrocampistas en ratios ilustran una estructura continua, con los roles ordenados en un gradiente sin fronteras nítidas. La coincidencia entre ambas técnicas respalda que la estructura es real.*

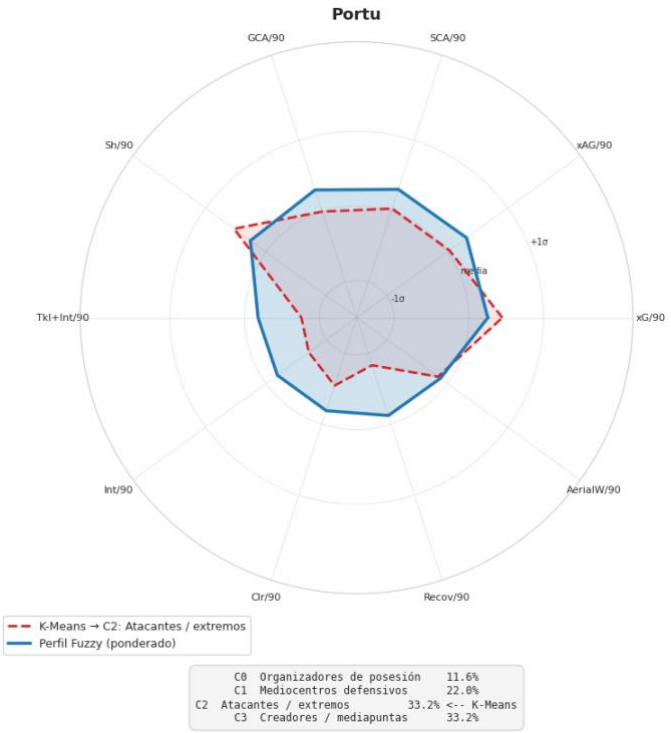


Figura 11. *Radar de Portu, con su perfil real frente al centroide del rol que K-means le asignó, atacantes/extremos, en sus métricas más representativas. El desajuste entre ambos perfiles, alto volumen de tiro pero escasa producción ofensiva, refleja que el jugador no encaja del todo en el rol asignado y explica su elevada ambigüedad.*

Relevo de Busquets			
Jugador	**Equipo**	**Edad**	**Similitud**
Mats Wieffer	Feyenoord	23	59,9
Martín Zubimendi	Real Sociedad	23	59,2
Ibrahim Sangaré	PSV Eindhoven	25	57,5
Lutsharel Geertruida	Feyenoord	22	54,5
Salis Abdul Samed	Lens	22	53,9
Youri Tielemans	Leicester City	25	53,7
Xaver Schlager	RB Leipzig	24	53,1
Manuel Locatelli	Juventus	25	52,8

Tabla 9. *Relevo joven para Sergio Busquets generado por el recomendador en modo direccional, con los filtros de edad igual o inferior a 25 años y exclusión de su club. La similitud está normalizada sobre 100.*

Perfil Haaland			
Jugador	**Equipo**	**Edad**	**Similitud**
Callum Wilson	Newcastle Utd	30	59,0
Victor Osimhen	Napoli	24	54,8
Robert Lewandowski	Barcelona	33	54,3
Loïs Openda	Lens	22	54,0
Wissam Ben Yedder	Monaco	31	53,7
Brian Brobbey	Ajax	21	53,3
Santiago Giménez	Feyenoord	22	52,7

Sébastien Haller	Dortmund	28	50,8

Tabla 10. *Jugadores con el perfil más similar a Erling Haaland, rol de 9 de área, según el recomendador en modo direccional. Similitud normalizada sobre 100.*

Jugador	Equipo	Edad	*Rating*	Valor (M€)	Residuo
Centrocampistas					
Thomas Delaine	Strasbourg	30	6.7	1.2	-41.4
Yves Bissouma	Tottenham	25	14.9	18.0	-38.5
Mitchel Bakker	Leverkusen	22	12.0	9.0	-37.2
Mohamed Elyounoussi	Southampton	27	15.4	9.0	-36.4
Jens Stage	Werder Bremen	25	14.2	5.0	-35.0
Defensas					
Saidy Janko	Bochum	26	10.3	1.0	-38.1
Aritz Elustondo	Real Sociedad	28	17.7	14.0	-35.4
Nathaniel Clyne	Crystal Palace	31	17.1	2.0	-34.7
Joel Ward	Crystal Palace	32	17.5	1.2	-33.9
Reinildo Mandava	Atlético Madrid	28	20.1	25.0	-33.8
Delanteros					
Divock Origi	Milan	28	16.3	6.0	-36.8
Emmanuel Gyasi	Spezia	29	16.0	2.0	-32.6
Adrien Hunou	Angers	28	17.5	2.5	-31.3
Gerrit Holtmann	Bochum	27	17.8	2.5	-30.7
Brennan Johnson	Nott'ham Forest	21	21.6	38.0	-30.3

Tabla 11. *Jugadores más sobrevalorados por línea, según el residuo del modelo rating ~ log(valor) + edad + edad² + club (configuración de ratios). Un residuo negativo grande indica un rating muy por debajo del que sugieren su valor, edad y club. El rating está en escala 0–100 y el valor en millones de euros.*

Jugador	Origen	Destino	Rol	*Rating*
Cody Gakpo	PSV Eindhoven	Liverpool	Del. Creadores puros	94.1
Pedro Porro	Sporting CP	Tottenham	Def. Laterales creadores	88.2
Enzo Fernández	Benfica	Chelsea	Cen. Organizadores de posesión	73.0
Julian Ryerson	Union Berlin	Dortmund	Def. Laterales generalistas	72.8
Mike te Wierik	Groningen	Emmen	Def. Centrales contundentes	72.5
Dango Ouattara	Lorient	Bournemouth	Cen. Atacantes / extremos	69.4
Terem Moffi	Lorient	Nice	Del. 9 de área	66.7
Karl Toko Ekambi	Lyon	Rennes	Cen. Atacantes / extremos	64.1
Mats Seuntjens	Fortuna Sittard	RKC Waalwijk	Cen. Organizadores de posesión	49.4
Adrien Thomasson	Strasbourg	Lens	Cen. Organizadores de posesión	44.0
Issiaga Sylla	Toulouse	Montpellier	Def. Laterales generalistas	43.5
Álex Moreno	Betis	Aston Villa	Def. Laterales generalistas	39.7
Sven Mijnans	Sparta R'dam	AZ Alkmaar	Cen. Organizadores de posesión	35.1
João Cancelo	Manchester City	Bayern Munich	Def. Laterales creadores	33.9
Weston McKennie	Juventus	Leeds United	Def. Centrales con salida	30.5
Leandro Trossard	Brighton	Arsenal	Cen. Creadores élite	28.4
Francesco Caputo	Sampdoria	Empoli	Del. 9 de área	5.2

Tabla 12. *Rating de origen de los jugadores transferidos en el mercado de invierno 2022/23, calculado solo con su rendimiento en el club de procedencia, ordenados de mayor a menor (configuración de ratios). Un rating alto seguido de un fichaje por un club de mayor nivel evidencia la capacidad de anticipación del sistema.*

Anexo C. Pesos de los enfoques de valoración

Este anexo recoge los pesos de los dos enfoques de valoración basados en ponderación de métricas, el experto y el SHAP direccional, para cada combinación de línea, configuración y rol. Los pesos del experto se asignan a mano según la importancia atribuida a cada métrica en el rol. Los del SHAP direccional son las importancias SHAP de las variables con contribución positiva, normalizadas para sumar uno dentro de cada rol.

Config.	Línea	Rol	Pesos por métrica (orden descendente)
volumen	Centrocampistas	Atacantes / extremos	xG/90 0.18, Gls/90 0.15, SoT/90 0.12, SCA/90 0.10, xAG/90 0.10, Sh/90 0.08, GCA/90 0.08, Dribbles/90 0.08, Fld/90 0.06, Dribbles% 0.05
volumen	Centrocampistas	Organizadores de posesión	PassesCompleted/90 0.12, TotDistPasses/90 0.10, PrgDistPasses/90 0.10, Passes% 0.10, PassesProgressive/90 0.10, Recov/90 0.10, Tkl+Int/90 0.10, MediumPasses% 0.08, LongPasses% 0.08, Int/90 0.06, AerialW/90 0.06
volumen	Centrocampistas	Mediocentros defensivos	Tkl+Int/90 0.22, Int/90 0.15, Recov/90 0.15, TklW/90 0.10, Blocks/90 0.08, Clr/90 0.08, AerialW/90 0.08, Aerial% 0.07, Passes% 0.07
volumen	Centrocampistas	Creadores / mediapuntas	xAG/90 0.18, xA/90 0.15, KP/90 0.14, SCA/90 0.12, GCA/90 0.10, PPA/90 0.08, Ast/90 0.08, PassesProgressive/90 0.08, FinalThirdPasses/90 0.07
ratios	Centrocampistas	Creadores élite	xAG/90 0.20, xA/90 0.15, KP/90 0.15, SCA/90 0.12, GCA/90 0.10, PPA/90 0.08, Ast/90 0.08, KP_ratio 0.06, F3_ratio 0.06
ratios	Centrocampistas	Organizadores de posesión	PrgPass_ratio 0.15, Passes% 0.12, PrgPass_per_touch 0.12, F3_ratio 0.12, MediumPasses% 0.10, Recov/90 0.10, Tkl+Int/90 0.10, LongPasses% 0.08, Int/90 0.06, AerialW/90 0.05
ratios	Centrocampistas	Mediocentros defensivos	Tkl+Int/90 0.22, Int/90 0.15, Recov/90 0.15, TklW/90 0.10, Blocks/90 0.08, Clr/90 0.08, AerialW/90 0.08, Aerial% 0.07, Passes% 0.07
ratios	Centrocampistas	Atacantes / extremos	xG/90 0.18, Gls/90 0.15, SoT/90 0.12, SCA/90 0.10, xAG/90 0.10, Drib_per_touch 0.10, Sh/90 0.08, GCA/90 0.08, Dribbles% 0.05, Fld/90 0.04
volumen	Defensas	Laterales creadores	CrsPA/90 0.15, PPA/90 0.12, xA/90 0.12, xAG/90 0.10, SCA/90 0.10, Tkl+Int/90 0.10, AerialW/90 0.09, KP/90 0.08, Recov/90 0.08, Ast/90 0.06
volumen	Defensas	Laterales generalistas	Tkl+Int/90 0.15, PassesProgressive/90 0.11, Int/90 0.10, Recov/90 0.10, CrsPA/90 0.10, AerialW/90 0.10, Passes% 0.10, PPA/90 0.08, xA/90 0.08, Aerial% 0.08
volumen	Defensas	Centrales con salida	Passes% 0.15, PassesProgressive/90 0.12, Tkl+Int/90 0.12, LongPasses% 0.10, PrgDistPasses/90 0.10, Int/90 0.10, TotDistPasses/90 0.08, Clr/90 0.08, AerialW/90 0.08, Aerial% 0.07
volumen	Defensas	Centrales contundentes	Clr/90 0.18, Tkl+Int/90 0.16, AerialW/90 0.15, Int/90 0.12, Aerial% 0.12, Blocks/90 0.10, TklW/90 0.08, Recov/90 0.05, Passes% 0.04

Config.	Línea	Rol	Pesos por métrica (orden descendente)
ratios	Defensas	Centrales contundentes	Clr/90 0.18, Tkl+Int/90 0.16, AerialW/90 0.15, Int/90 0.12, Aerial% 0.12, Blocks/90 0.10, TklW/90 0.08, Recov/90 0.05, Passes% 0.04
ratios	Defensas	Laterales creadores	CrsPA/90 0.15, PPA/90 0.12, xA/90 0.12, xAG/90 0.10, SCA/90 0.10, Tkl+Int/90 0.10, AerialW/90 0.09, KP/90 0.08, Recov/90 0.08, Ast/90 0.06
ratios	Defensas	Centrales con salida	Passes% 0.15, PrgPass_ratio 0.12, Tkl+Int/90 0.12, LongPasses% 0.10, F3_ratio 0.10, Int/90 0.10, PrgPass_per_touch 0.08, Clr/90 0.08, AerialW/90 0.08, Aerial% 0.07
ratios	Defensas	Laterales generalistas	Tkl+Int/90 0.15, PrgPass_ratio 0.11, Int/90 0.10, Recov/90 0.10, CrsPA/90 0.10, AerialW/90 0.10, Passes% 0.10, PPA/90 0.08, xA/90 0.08, Aerial% 0.08
volumen	Delanteros	Creadores de posesión	KP/90 0.12, xAG/90 0.12, xA/90 0.10, SCA/90 0.10, PassesCompleted/90 0.10, PassesProgressive/90 0.10, TotDistPasses/90 0.08, Passes% 0.08, PPA/90 0.08, Ast/90 0.06, Recov/90 0.06
volumen	Delanteros	9 de área	Gls/90 0.20, xG/90 0.18, G-PK/90 0.12, SoT/90 0.10, AerialW/90 0.10, xG_per_shot 0.10, Aerial% 0.08, Sh/90 0.06, PPA/90 0.06
volumen	Delanteros	Extremos de élite	xG/90 0.15, Gls/90 0.12, xAG/90 0.12, SCA/90 0.12, xA/90 0.10, GCA/90 0.10, KP/90 0.08, PPA/90 0.08, Dribbles/90 0.08, Ast/90 0.05
volumen	Delanteros	Extremos trabajadores	SCA/90 0.12, KP/90 0.10, PPA/90 0.10, xAG/90 0.10, Tkl+Int/90 0.10, Recov/90 0.10, CrsPA/90 0.08, xA/90 0.08, Dribbles/90 0.08, Fld/90 0.08, xG/90 0.06
ratios	Delanteros	9 de área	Gls/90 0.20, xG/90 0.18, G-PK/90 0.12, SoT/90 0.10, AerialW/90 0.10, xG_per_shot 0.10, Aerial% 0.08, Sh/90 0.06, PPA/90 0.06
ratios	Delanteros	Extremos trabajadores	SCA/90 0.12, Tkl+Int/90 0.12, KP/90 0.10, xAG/90 0.10, Int/90 0.10, Recov/90 0.10, CrsPA/90 0.08, xA/90 0.08, PPA/90 0.08, Ast/90 0.06, Fld/90 0.06
ratios	Delanteros	Extremos de desequilibrio	Drib_per_touch 0.15, SCA_per_touch 0.12, Dribbles% 0.10, SCA/90 0.10, CrsPA/90 0.08, KP/90 0.08, xAG/90 0.08, Fld/90 0.08, xA/90 0.07, PrgPass_per_touch 0.07, Ast/90 0.07
ratios	Delanteros	Creadores puros	xG/90 0.15, Gls/90 0.12, xAG/90 0.12, SCA/90 0.12, xA/90 0.10, GCA/90 0.10, KP/90 0.08, PPA/90 0.08, G-PK/90 0.08, Ast/90 0.05

Tabla 13. *Pesos del enfoque experto por línea, configuración y rol. Cada conjunto suma uno y refleja la importancia que el criterio futbolístico atribuye a cada métrica dentro del rol.*

Config.	Línea	Rol	Pesos SHAP normalizados (orden descendente)
volumen	Centrocampistas	Organizadores de posesión	Touches/90 0.16, TotDistPasses/90 0.13, PassesAttempted/90 0.13, MediumPassesCompleted/90 0.12, PassesCompleted/90 0.12, PrgDistPasses/90 0.08, FinalThirdPasses/90 0.07, PassesProgressive/90 0.06, ShortPassesCompleted/90 0.05, Tkl+Int/90 0.03, Recov/90 0.03, LongPassesCompleted/90 0.02

Config.	Línea	Rol	Pesos SHAP normalizados (orden descendente)
volumen	Centrocampistas	Mediocentros defensivos	MediumPassesCompleted/90 0.27, PrgDistPasses/90 0.17, Tkl+Int/90 0.15, Clr/90 0.12, Int/90 0.08, TklW/90 0.05, Recov/90 0.04, MediumPasses% 0.03, Blocks/90 0.03, LongPassesCompleted/90 0.03, Passes% 0.02, Aerial% 0.02
volumen	Centrocampistas	Atacantes / extremos	SoT/90 0.34, Sh/90 0.27, xG/90 0.18, Gls/90 0.07, G-PK/90 0.07, xGD/90 0.05, CrsPA/90 0.02
volumen	Centrocampistas	Creadores / mediapuntas	xA/90 0.15, KP/90 0.15, SCA/90 0.13, PPA/90 0.10, GCA/90 0.09, xAG/90 0.08, SoT/90 0.06, Touches/90 0.06, TotDistPasses/90 0.05, PassesCompleted/90 0.05, Ast/90 0.04, xG/90 0.04
ratios	Centrocampistas	Mediocentros defensivos	Clr/90 0.20, Int/90 0.17, Tkl+Int/90 0.15, FinalThirdPasses/90 0.08, AerialW/90 0.06, Def_per_touch 0.06, Recov/90 0.06, Blocks/90 0.06, MediumPasses% 0.05, TklW/90 0.04, Passes% 0.03, Aerial% 0.03
ratios	Centrocampistas	Organizadores de posesión	SCA_per_touch 0.18, FinalThirdPasses/90 0.17, SCA/90 0.12, MediumPasses% 0.10, F3_ratio 0.08, PrgPass_per_touch 0.08, Passes% 0.08, ShortPasses% 0.06, PrgPass_ratio 0.04, PPA/90 0.04, LongPasses% 0.03, KP/90 0.03
ratios	Centrocampistas	Creadores élite	SCA/90 0.18, xAG/90 0.14, xA/90 0.11, GCA/90 0.09, KP/90 0.08, PPA/90 0.08, SoT/90 0.08, KP_ratio 0.08, xG/90 0.05, SCA_per_touch 0.05, Sh/90 0.04, Ast/90 0.04
ratios	Centrocampistas	Atacantes / extremos	SCA_per_touch 0.21, SoT/90 0.20, KP_ratio 0.13, xG/90 0.13, Sh/90 0.12, Gls/90 0.07, G-PK/90 0.06, Drib_per_touch 0.03, SoT_ratio 0.02, xG_per_shot 0.01, CrsPA/90 0.01, xGD/90 0.01
volumen	Defensas	Centrales contundentes	Clr/90 0.30, Int/90 0.17, MediumPasses% 0.11, Tkl+Int/90 0.10, Blocks/90 0.07, AerialW/90 0.06, xGA/90 0.05, Recov/90 0.05, Aerial% 0.02, TklW/90 0.02, Dribbles% 0.02, Fls/90 0.01
volumen	Defensas	Laterales generalistas	SCA/90 0.34, xAG/90 0.13, KP/90 0.10, CrsPA/90 0.10, PPA/90 0.09, xA/90 0.08, Sh/90 0.04, GCA/90 0.03, SoT/90 0.03, xGD/90 0.03, Ast/90 0.02, xG/90 0.01
volumen	Defensas	Laterales creadores	SCA/90 0.18, PPA/90 0.15, Touches/90 0.13, PassesAttempted/90 0.10, KP/90 0.10, CrsPA/90 0.08, xA/90 0.06, TotDistPasses/90 0.05, xAG/90 0.05, PassesCompleted/90 0.04, ShortPassesCompleted/90 0.03, PrgDistPasses/90 0.02
volumen	Defensas	Centrales con salida	TotDistPasses/90 0.19, PassesAttempted/90 0.14, PassesCompleted/90 0.14, MediumPassesCompleted/90 0.13, Touches/90 0.11, MediumPasses% 0.07, PrgDistPasses/90 0.07, FinalThirdPasses/90 0.03, Passes% 0.03, PassesProgressive/90 0.03, LongPassesCompleted/90 0.03, LongPasses% 0.02
ratios	Defensas	Laterales creadores	SCA_per_touch 0.18, KP_ratio 0.13, SCA/90 0.11, Sh/90 0.09, SoT/90 0.09, xAG/90 0.09, GCA/90 0.06, xG/90 0.06, CrsPA/90 0.05, Gls/90 0.05, xGD/90 0.04, PPA/90 0.04

Config.	Línea	Rol	Pesos SHAP normalizados (orden descendente)
ratios	Defensas	Centrales contundentes	Clr/90 0.34, MediumPasses% 0.20, xGA/90 0.15, AerialW/90 0.08, Blocks/90 0.06, Def_per_touch 0.04, Int/90 0.03, LongPass_ratio 0.03, Tkl+Int/90 0.02, xG_per_shot 0.01, Aerial% 0.01, Dribbles% 0.01
ratios	Defensas	Centrales con salida	MediumPasses% 0.20, Passes% 0.12, F3_ratio 0.12, xGD/90 0.12, FinalThirdPasses/90 0.11, PrgPass_per_touch 0.10, LongPasses% 0.07, SCA/90 0.07, PrgPass_ratio 0.05, ShortPasses% 0.04, AerialW/90 0.01, Aerial% 0.01
ratios	Defensas	Laterales generalistas	CrsPA/90 0.21, KP_ratio 0.15, SCA_per_touch 0.14, SCA/90 0.12, PPA/90 0.11, KP/90 0.06, Drib_per_touch 0.04, xGA/90 0.04, Def_per_touch 0.04, Tkl+Int/90 0.03, TklW/90 0.02, Int/90 0.02
volumen	Delanteros	9 de área	xG/90 0.31, Gls/90 0.14, SoT/90 0.12, G-PK/90 0.10, Sh/90 0.08, AerialW/90 0.08, xGD/90 0.07, Aerial% 0.04, LongPasses% 0.02, Clr/90 0.02, Fls/90 0.01, Fld/90 0.01
volumen	Delanteros	Creadores de posesión	Touches/90 0.18, PassesAttempted/90 0.13, TotDistPasses/90 0.13, PrgDistPasses/90 0.10, Recov/90 0.09, PassesCompleted/90 0.07, Int/90 0.07, MediumPassesCompleted/90 0.06, Tkl+Int/90 0.06, ShortPassesCompleted/90 0.04, PassesProgressive/90 0.03, Clr/90 0.03
volumen	Delanteros	Extremos de élite	SCA/90 0.12, Gls/90 0.10, TotDistPasses/90 0.10, PassesAttempted/90 0.09, PassesCompleted/90 0.09, GCA/90 0.08, Touches/90 0.08, PassesProgressive/90 0.07, KP/90 0.07, PrgDistPasses/90 0.07, G-PK/90 0.06, xGD/90 0.06
volumen	Delanteros	Extremos trabajadores	PrgDistPasses/90 0.24, Recov/90 0.22, MediumPassesCompleted/90 0.13, Tkl+Int/90 0.12, Int/90 0.08, TklW/90 0.05, Dribbles/90 0.04, CrsPA/90 0.04, ShortPasses% 0.03, Blocks/90 0.02, Passes% 0.01, xGA/90 0.01
ratios	Delanteros	Extremos de desequilibrio	SCA_per_touch 0.23, CrsPA/90 0.15, LongPass_ratio 0.13, xGD/90 0.13, PrgPass_per_touch 0.10, ShortPasses% 0.10, Def_per_touch 0.06, Dribbles/90 0.05, PrgPass_ratio 0.03, Drib_per_touch 0.03
ratios	Delanteros	9 de área	xG/90 0.24, AerialW/90 0.20, Gls/90 0.14, xG_per_shot 0.12, G-PK/90 0.11, SoT/90 0.06, Clr/90 0.04, Sh/90 0.03, Aerial% 0.02, xGD/90 0.01, SoT_ratio 0.01, xGA/90 0.01
ratios	Delanteros	Creadores puros	SCA/90 0.17, KP/90 0.15, xA/90 0.12, PPA/90 0.11, GCA/90 0.10, xAG/90 0.08, Gls/90 0.07, G-PK/90 0.05, xG/90 0.05, SoT/90 0.03, Recov/90 0.03, FinalThirdPasses/90 0.03
ratios	Delanteros	Extremos trabajadores	Tkl+Int/90 0.25, Recov/90 0.18, Int/90 0.16, TklW/90 0.09, Blocks/90 0.05, FinalThirdPasses/90 0.05, Def_per_touch 0.04, KP/90 0.04, PPA/90 0.04, Clr/90 0.04, xA/90 0.03, xGA/90 0.03

Tabla 14. *Pesos del filtrado SHAP direccional por línea, configuración y rol. Son las importancias SHAP de las variables con signo positivo, reducidas a las doce principales y normalizadas para sumar uno.*

Anexo D. Diagnósticos del modelo de regresión

La validación externa de la sección 5.4 ajusta, dentro de cada línea, el modelo rating = β_0 + β_1 log(valor) + β_2 edad + β_3 edad² + β_4 club + ε sobre la configuración de ratios. El residuo de cada jugador, su rating real menos el predicho, es lo que mide su infravaloración o sobrevaloración respecto al mercado. La tabla recoge el ajuste y la significatividad de cada coeficiente, y la figura muestra los residuos frente a los valores predichos.

	Centrocampistas	Defensas	Delanteros
N observaciones	685	676	506
R^2	0.055	0.021	0.045
R^2 ajustado	0.049	0.015	0.038
p-valor (F)	<0.001	0.006	<0.001
Constante	-2.634	-5.121	-2.120
log(valor)	2.608***	1.342*	2.123***
edad	0.423	2.075	1.124
edad²	0.002	-0.028	-0.015
club top	0.907	-0.768	2.416

Tabla 15. *Diagnósticos del modelo de regresión por línea (configuración de ratios). Ajuste global (R^2 y p-valor del estadístico F) y coeficientes con su significatividad. Significatividad: *** p<0.001, ** p<0.01, * p<0.05.*

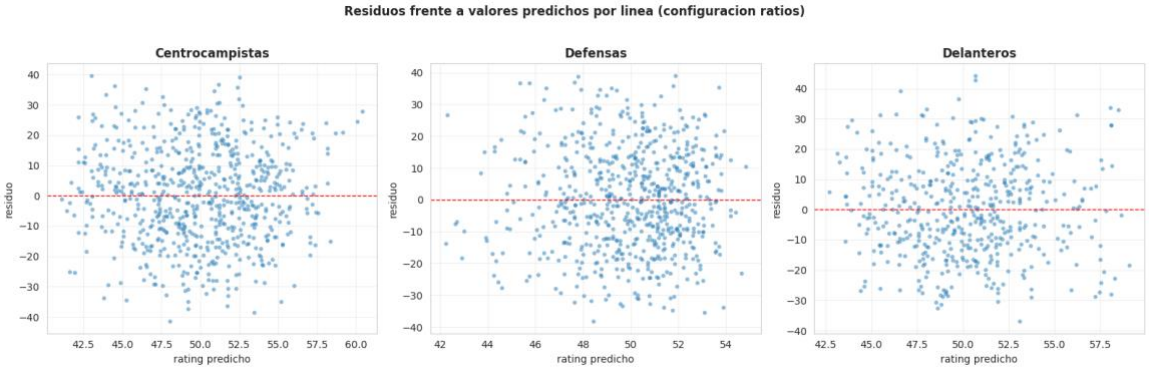


Figura 12. *Residuos frente a valores predichos por línea (configuración de ratios). La nube se reparte de forma simétrica en torno a cero sin patrón aparente, lo que apoya el uso del modelo lineal para obtener los residuos.*